

BraTS-Lighthouse 2025 — Task 8 (BraTS-Synth)

缺失 MRI 模态合成 — 7 篇论文算法总结

MICCAI 2025 · LNCS 16377 · Proceedings Part II

2026-06-08

收录论文

- 1. MMHVAE — Reuben Dorent (Inria Paris)
- 2. No More Slice Wars — Carpentiero, Bolelli 等 (Univ. of Modena)
- 3. Latent-Space Ensemble Synthesis — Gonthulerie 等 (Univ. of Girona) ★ 第 2 名
- 4. MISFIT — Banerjee 等 (MBZUAI)
- 5. Fast-cWDM — Sereda, Chato (Univ. of South Dakota) ★ 第 3 名
- 6. SLaM-DiMM — Sandbhor 等 (IIT Bombay)
- 7. DiffuseMRI — Zhang, Tansey (UT Austin / MSKCC) 验证集 SOTA

排名说明：论文 (3) 自述获第 2 名，(5) 自述获第 3 名，(7) 在验证集上超过 BraSyn 2024 冠军及亚军。
第 1 名方案未收录于本卷，或为 MMHVAE / 其他方案。

数据来源：Bakas et al. (Eds.), Segmentation, Classification, and Synthesis for Brain Tumors and Traumatic Brain Injuries, LNCS 16377, Springer Nature Switzerland AG 2026.

1. MMHVAE — Unified Brain MRI Synthesis with Mixture of Multimodal Hie

Reuben Dorent | Inria Saclay / Paris Brain Institute

核心方法

- 层级 VAE: 6 级隐变量 ($L=6$), 最粗 $1 \times 1 \times 256 \rightarrow$ 最细 $192 \times 224 \times 8$
- 混合后验: $q(z|x_o) = \sum \alpha(r) \cdot q(z|x_{or})$, 对所有观测子集 $r \subset S_1$ 加权混合
- Product-of-Experts 闭式解融合各模态均值/方差 (公式 5)
- 2D U-Net: MobileNetV2 残差单元 + Squeeze-and-Excitation + Swish
- 解码器: 5 个 ResNet 块, 推理温度 0.5
- 两阶段训练: 前 800 epoch 纯 VAE ($\lambda_{KL}=0.001$), 后 200 epoch + GAN ($\lambda_{GAN}=0.025$)
- 数据 Harmonization: SynthSeg 白质中位强度对齐 $\rightarrow$ 仅应用于 GT 目标
- H100 40GB x 35h, batch_size=16

关键创新

- 单一模型处理任意缺失组合 (真正统一的框架)
- 混合后验: 鼓励编码可用信息 + 估计缺失信息
- 层级隐空间捕获多尺度脑结构
- Contrast Harmonization 解决多中心采集差异
- 已在多模态超声、分割、关键点匹配等下游验证

性能表现

- 肿瘤区域 SSIM $\geq 99.7\%$ (所有模态)
- 非肿瘤 SSIM 平均 94.1%
- 下游分割 Dice: WT 91.4%, TC 71.1%, ET 68.7%
- T1ce 最难 (ET Dice 仅 19.3%)
- 测试集: SSIM 93.8%, WT 85.7%, TC 74.8%, ET 69.3%

备注

代码: github.com/ReubenDo/MMHVAE

2. No More Slice Wars — Enhanced HF-GAN for Harmonized Brain MRI Syn

O. Carpentiero, K. Marchesini, C. Grana, F. Bolelli | Univ. of Modena and Reggio Emilia

核心方法

- 基于 BraSyn 2024 冠军 HF-GAN 的增强 2D 框架
- Encoder: 4 个模态专用 late-fusion + 1 个 early-fusion (grouped conv 并行)
-> 缺失模态通道填 -1; CAFF 模块做注意力融合
- Modality Infuser: 4 层 FlashAttention 兼容 MHA 替代原始 Transformer
- 预处理: 99.5% 裁剪 + z-score 归一化 (替代原版 min-max)
背景 voxel 统一为 -1 -> 无需强度编码器
- 轻量 2D nnU-Net Segmenter (1.79M): 4 级 [32,64,128,256], Focal Tversky 训练后冻结
- 多视图训练 (Axial + Sagittal), 推理 13.4 秒/样本 (RTX5000)
- Loss: $10 \cdot L_{\text{recon}} + 0.25 \cdot L_{\text{adv}} + 0.25 \cdot L_{\text{class}} + L_{\text{feat}} + L_{\text{cycle}} + 5 \cdot L_{\text{SSIM}} + 5 \cdot L_{\text{Tversky}}$
- Cycle consistency: 2 次前向, 8 次网络传递, 梯度聚合后一次反向传播

关键创新

- z-score 归一化 (99.5% 裁剪) 比 min-max 更稳健
- Grouped conv 并行化 early-fusion 加速
- 双 SSIM: 健康/肿瘤组织分别计算 -> 显著提升 WT SSIM
- FlashAttention 替代自注意力
- 支持可变数量已知模态 (1/2/3) 训练

性能表现

- 验证集 SSIM: WT 99.76%, HT 94.09% (GLI+MET)
- 验证集 Dice: ET 57.70%, TC 75.11%, WT 74.97%
- 测试集 (最佳 R8S): SSIM 93.33%, WT 85.29%, TC 77.50%, ET 72.34%
- 无 3D 后处理仍无条纹伪影 (多视图训练贡献)

备注

代码: github.com/AlmageLab-zip/BraSyn25

3. Latent-Space Ensemble Synthesis of Missing Brain Tumor MRI Modalities★第2名

A. Cartaya Lathulerie, V. Abramova, M. Rivas Díaz 等 | University of Girona

核心方法

- 预训练 VCN (MAISI): 3D VAE, $256^3 \rightarrow 4$ 通道 $\times 64 \times 64 \times 40$ 隐空间
在大规模 CT/MRI 上预训练, 不微调, 泛化良好
- MT-ED (Encoder-Decoder): 编码+融合可用模态 $\rightarrow$ 直接解码缺失模态
加权 L2: $w_k = \{0.51, 0.12, 0.20, 0.16\}$ (按各隐空间通道对重建的贡献)
- MT-BBDM (Brownian Bridge Diffusion): $x_0 \leftrightarrow x_T$ 双端点桥接扩散
 $m_t = t/T$ 线性桥接; 分别对肿瘤/健康区域算 L2
1000 步训练 $\rightarrow$ 50 步 DDIM 加速采样
- 推理: 两模型输出平均集成 $\rightarrow$ VCN 解码 $\rightarrow$ 裁剪/归一化
- 训练 4 个模态专用模型, A30 24GB, batch=4

关键创新

- 预训练 VCN 全卷压缩: 避免 slice/patch 的空间不连续
- Brownian Bridge: 天生适合图像到图像翻译 (非纯噪声 $\rightarrow$ 图像)
- 隐空间操作: 3D 全卷 + 低计算量
- 简单平均集成即有效 (SSIM 0.9257 $\rightarrow$ 0.9322)
- 标准化对照评估 (Rec GT 上界)

性能表现

- SSIM: 集成 0.9322 > MT-ED 0.9257 > BBDM 0.9234
- 肿瘤区域 SSIM: 集成 0.9971 (接近 Rec GT 0.9991)
- 测试集: SSIM 93.71%, WT 86.19%, TC 78.47%, ET 73.93%
- T1ce 最差 (SSIM 0.9203), FLAIR 次之

备注

代码: github.com/AgustinCartaya/brats2025-latent-ensemble-synthesis

4. MISFIT — Modality Inference via Style Fusion and Invertible Translation

M. Banerjee, Q. Ji, S. Hashmi, A. Elsayed 等 | MBZUAI

核心方法

- 全小波域两阶段框架
- Stage I (融合+风格迁移):
3D Haar DWT -> 每模态 8 子带 -> CAFF 融合 (通道注意力 + softmax 注意力)
-> MS-SPADE 条件生成器 (目标模态类标签做 affine 变换) -> 8 子带粗估计 Y0
Loss: MSE (子带) + 对抗分类 loss (多类判别器)
- Stage II (条件小波扩散):
条件 = CAFF输出 + Y0 + 3 源 DWT = 5 通道拼接
Palette-style: 条件在每步与噪声输入拼接 -> 3D U-Net (64 base) 预测去噪子带
1000 步 cosine 噪声调度 + DDPM 采样
- 4 个独立模型, 4xA100 DDP + mixed precision

关键创新

- 首次将 CAFF + SPADE 引入小波扩散 (cWDM 增强)
- 两阶段解耦: 融合 (Stage I) + 生成 (Stage II) 分离
- MS-SPADE: 按目标模态自适应调制特征
- 完全小波域 -> 无独立编码器-解码器 -> 保留空间信息
- 作者注明受限于训练 (150K vs cWDM 1.2M steps)

性能表现

- PSNR: 随机缺失 18.65 dB, T1ce 最好 20.15 dB
- SSIM: 随机缺失 0.8041 (受限于训练步数, 下界估计)
- 对比 cWDM 论文 (SSIM > 0.93), 差距主要来自训练不充分

备注

代码: github.com/mohrsalt/MISFIT

5. Fast-cWDM — Fast Conditional Wavelet Diffusion Model for Synthesis Brats

Timothy Sereda, Lina Chato | University of South Dakota

核心方法

- Fast-DDPM 快速采样 + cWDM 小波域 = 仅 100 扩散步!
- 预处理: $224^3 \rightarrow$ Haar DWT $\rightarrow 112^3 \times 8$ 子带
条件 = 3 可用模态 DWT (24 通道) + 噪声目标 (8 通道) = 32 通道输入
- 轻量 3D U-Net 在 $1/8$ 空间尺度操作 $\rightarrow$ 大幅降低显存
- DDIM 非马尔可夫采样 (加速)
- 训练 3 阶段: 47.5K $\rightarrow$ 200K $\rightarrow$ 600K iter, AdamW lr=1e-5, batch=1
- 4xA100 40GB, 每模态训练 ~89h, 推理 41-67 秒/样本
- 纯 MSE loss, 无需对抗/感知 loss

关键创新

- Fast-DDPM 首次应用于小波扩散: 速度提升 ~10x
- 推理极快 (41-67 秒 vs 通常 >10 分钟)
- 100 步即达 SSIM ~0.94, 可部署于临床
- 简单高效 (纯 MSE, 无复杂 loss)
- 探索方向: db2/db4 小波、注意力、多任务学习

性能表现

- T1 最佳: PSNR 28.38 dB, SSIM 0.9391
- T1ce 最差: PSNR 26.23 dB, SSIM 0.9097
- 下游 nnU-Net: WT 0.877, TC 0.769, ET 0.667
真实 4 模态上限: WT 0.897, TC 0.851, ET 0.778
- 测试集: SSIM 92.91%, WT 86.09%, TC 77.30%, ET 72.53%

备注

代码: github.com/tsereda/brats-synthesis

6. SLaM-DiMM — Shared Latent Modeling for Diffusion Based Missing Modality MRI

B. Sandbhor, B. Sharma, B. Palaniappan | IIT Bombay

核心方法

- 两阶段：MMG (缺失模态生成) + CEn (一致性增强)
- MMG — 共享隐空间扩散：
共享编码器 E (OpenAI UNet 下采样) -> 隐空间 $z = E(x)$
-> LDM 扩散瓶颈 (T=1000 训练, T/2=500 采样 DDPM) -> 4 个模态专用解码器 D_m
输入: 4 通道 2D 轴向切片 (缺失通道填 0)
Loss: $(x - x^{\sim}) \cdot (1 + \lambda_1 S)^2$ [$S = \text{肿瘤mask}, \lambda_1 = 4$] + $\lambda_2 ||z - z^{\sim}||^2$ [隐空间一致性, $\lambda_2 = 2$]
+ $\gamma_1 \cdot (1 - \text{SSIM})$ [$\gamma_1 = 0.5$]
- CEn — 3D UNETR 后处理：
滑动窗口子体积 (深度 16, stride 8) -> Transformer+3D UNet
Loss: $L_{3Drec} + \gamma_2 \cdot L_{3DSSIM}$ [$\gamma_2 = 0.1$]
- 单卡 RTX A6000 48GB, MMG 1600 epoch, CEn 250 epoch

关键创新

- 共享隐空间 + 模态专用解码器：统一与专用兼顾
- LDM 瓶颈在隐空间 (非图像空间) 扩散 -> 降低计算
- 分割引导训练 loss：无需推理时提供 mask
- 隐空间一致性正则化 (防止扩散扭曲编码特征)
- 专用 CEn 消除 2D 切片法的条纹伪影

性能表现

- MMG SSIM: Glioma T1w 94.96%, Metastasis Flair 89.41%
- CEn 对 Metastasis 有小幅提升 (T2w: 89.61 -> 90.39)
- MMG 分割: WT 89.93%, TC 76.01%, ET 78.73% (Glioma)
- 测试集 (MMG only): SSIM 92.55%, WT 85.72%, TC 77.78%, ET 72.15%

备注

代码见论文内链接

7. DiffuseMRI — Controllable Diffusion-Based Generation for MRI

验证集 SOTA MRI

Haoran Zhang, Wesley Tansey | UT Austin / Memorial Sloan Kettering Cancer Center

核心方法

- 基于 DiffuseTME (空间蛋白质组学扩散框架), EDM 扩散
- 层级特征注入 (Hierarchical Feature Injection):
观测模态 -> 辅助 UNet -> 多分辨率特征图
-> 加法注入主去噪分支对应解码器层 (像素级对齐)
- 双通道注意力:
Soft CA: GAP->FC->Sigmoid 通道加权 (SE 风格)
Full CA: QKV attention 沿通道维度 (建模模态间关系)
- Uniform Random Masking: 每步均匀随机选 1 个模态 mask
(替代 Bernoulli -> 对齐训练-测试分布, 减少方差)
- 联合输出 5 通道: 4 MRI + 1 分割掩码 (仅扩散 loss)
- 单一模型 (vs 4 个独立模型), 训练 ~12h, 4xA100, batch=32

关键创新

- 唯一真正统一的单一模型 (其他大多训练 4 个)
- 层级注入 + 双注意力 = 最丰富的条件建模
- Uniform masking 巧妙对齐训练/测试条件分布
- 联合分割预测 (无额外 head)
- 验证集超过 HF-GAN (BraSyn24 冠军) 和 SwinUNETR (亚军)
- 架构天然可扩展到 DWI/DTI/PWI 等序列

性能表现

- 验证集: SSIM tumor 0.774, SSIM tissue 0.643, DICE 0.738
vs HF-GAN: SSIM tissue 0.615, DICE 0.714
- 测试集: SSIM 92.49%, WT 85.05%, TC 75.94%, ET 71.25%
- Meningioma (未见训练) 泛化良好: SSIM 92.80%

备注

基于 DiffuseTME (arxiv:2507.02902)

Task 8 七种算法横向对比

方法	范式	维度	统一	核心机制	训练成本	SSIM↑	WT Dice↑
----	----	----	----	------	------	-------	----------

MMHVAE	VAE+GAN	2D	[Y]	层级混合后验+Harmonization	H100x35h	93.8%	85.7%
HF-GAN增强	GAN	2D->3D	[Y]	z-score+多视图+分割引导	RTX5000	93.3%	85.3%
Latent Ensemble	VAE+ED+BBDM	3D隐	[N]	x4 MAISI预训练+Bridge集成	A30	93.7%	86.2%
MISFIT*	小波扩散	3D	[N]	x4 CAFF+MS-SPADE两阶段	4xA100	80.4%	—
Fast-cWDM	小波扩散	3D	[N]	x4 100步DDIM+轻量U-Net	4xA100x89h	92.9%	86.1%
SLaM-DiMM	隐空间扩散	2D+3D	[Y]	共享编码器+LDM+UNETR	A6000x48G	92.6%	85.7%
DiffuseMRI	扩散	2D	[Y]	层级注入+双注意力+联合seg	4xA100x12h	92.5%	85.1%

* MISFIT 训练不充分 (150K vs cWDM 1.2M steps), SSIM 为下界估计
SSIM 和 Dice 均为测试集 hidden test set 官方结果, 由 BraSyn 2025 组织者计算。

关键趋势与技术总结

1. 小波扩散路线占据半壁江山

3 篇论文 (MISFIT, Fast-cWDM, 以及你当前使用的 BraSyn 2024 基线 cWDM/WDM) 采用小波域扩散。

优势: 在 1/8 空间尺度操作 -> 低显存、快训练、保留高频细节。Fast-cWDM 进一步将步数降至 100, 推理仅需 41-67

MISFIT 在两阶段融合上做了增强但受限于训练不充分。

2. 统一模型 vs 4 个独立模型

MMHVAE、SLaM-DiMM、DiffuseMRI 用单一模型处理所有缺失组合 -> 灵活、部署简单。

Latent Ensemble、MISFIT、Fast-cWDM 训练 4 个模态专用模型 -> 每模态独立优化、但维护成本高。

趋势: 统一模型在测试集上与专用模型差距很小, DiffuseMRI 甚至超越专用模型基线。

3. 隐空间 / 频域变换是主流

7 篇中仅 MMHVAE 直接在图像空间操作, 其余均使用压缩:

小波变换 (3篇)、VAE 隐空间 (2篇)、UNet 编码隐空间 (2篇)

压缩的好处: 3D 全卷成为可能、显存可控、训练加速。

4. 分割引导是重要辅助

SLaM-DiMM: 训练 loss 中肿瘤区域加权 ($\lambda_1=4$)

HF-GAN: 冻结 nnU-Net 提供 Tversky loss

DiffuseMRI: 联合输出分割掩码 (仅扩散 loss)

趋势: 利用分割信息改善肿瘤区域合成质量, 但不增加推理依赖。

5. 最佳测试集指标参考

SSIM: 93.7% (Latent Ensemble) ~ 92.5% (DiffuseMRI), 差异很小

WT Dice: 86.2% (Latent Ensemble) ~ 85.1% (DiffuseMRI)

TC Dice: 78.5% (Latent Ensemble) ~ 75.9% (DiffuseMRI)

ET Dice 仍是最大挑战 (69-74%), 尤其是 T1ce 合成。

6. 与你当前工作的关联

你使用的 BraSyn 2024 基线是 cWDM (Conditional Wavelet Diffusion), 与 Fast-cWDM (第3名) 和 MISFIT 同属小波

Fast-cWDM 的 100 步 DDIM 采样可直接参考移植。

MISFIT 的 CAFF + SPADE 融合可作为增强方向。

若需固定 T2W 缺失场景, 可考虑训练单一模态专用模型 (如 Latent Ensemble / Fast-cWDM 的 4 模型策略)。