

超算登录节点API 代理服务使用文档

适用场景：大模型 API 代理、外部 API（PubChem 等）内网转发；超算计算节点无法联网，但是在计算作业时需要使用调用外部api接口

服务绑定 IP： 10.11.100.254 （唯一可访问地址，其他 IP 均无法连接）八期登录节点login02

端口范围： 5000~5010 （系统自动分配空闲端口，无需手动指定）

二、使用前提

1. 登录超算集群login02节点(59.78.189.133);
2. 集群已配置 Python 3 环境（兼容 Python 2）；
3. 需代理的目标接口可正常访问（大模型 API、外部 API 等）。
4. 遵守中心算力使用规范与网络安全管理规定。

三、快速使用指南

在python下安装requests、flask

```
pip install requests flask
```

3.1 启动代理服务

执行以下命令，系统自动分配端口、绑定 IP、完成配置：

通用启动命令

```
python /public/software/profile.d/api_proxy.py \  
--target "目标接口地址" \  
--name "服务自定义名称" &
```

示例 1：大模型 API 代理（沐曦 Qwen3-VL-30B）

```
python /public/software/profile.d/api_proxy.py \  
--target http://59.78.189.xxx:8888 \  
--name "Qwen3-VL-30B-A3B-Instruct" &
```

启动代理：

```
(base) [ecnuhpc@login2 ~]$ python /public/software/profile.d/api_proxy.py \  
> --target http://59.78.189.█:8888 \  
> --name "Qwen3-VL-30B-A3B-Instruct" &  
[1] 71508  
(base) [ecnuhpc@login2 ~]$  
  
=====
```

■ 服务启动成功： Qwen3-VL-30B-A3B-Instruct

🕒 目标接口： http://59.78.189.█:8888

🌐 绑定网卡地址： http://10.11.100.254:5000

📖 【无感调用指南】

已开启完全无感模式，您可以直接在局域网其他主机上发起请求：

🕒 调用示例 (CURL)：

```
curl http://10.11.100.254:5000
```

请求模型：

```
[root@login1 ~]# curl http://10.11.100.254:5000/v1/models  
{  
  "object": "list",  
  "data": [  
    {  
      "id": "/models/Qwen3-VL-30B-A3B-Instruct",  
      "object": "model",  
      "created": 1774347457,  
      "owned_by": "vllm",  
      "root": "/models/Qwen3-VL-30B-A3B-Instruct",  
      "parent": null,  
      "max_model_len": 20477,  
      "permission": [  
        {  
          "id": "modelperm-477f5a458e7840ae92350880a538ceae",  
          "object": "model_permission",  
          "created": 1774347457,  
          "allow_create_engine": false,  
          "allow_sampling": true,  
          "allow_logprobs": true,  
          "allow_search_indices": false,  
          "allow_view": true,  
          "allow_fine_tuning": false,  
          "organization": "*",  
          "group": null,  
          "is_blocking": false  
        }  
      ]  
    }  
  ]  
}  
[root@login1 ~]# curl http://10.11.100.254:5000/v1/chat/completions \  
> -H "Content-Type: application/json" \  
> -d '{  
>   "model": "/models/Qwen3-VL-30B-A3B-Instruct",  
>   "messages": [  
>     {  
>       "role": "user",  
>       "content": "你好！"  
>     }  
>   ],  
>   "temperature": 0.7  
> }'  
{  
  "id": "chatcmpl-4ff6797fe00442b08a295c1872c5b209",  
  "object": "chat.completion",  
  "created": 1774347502,  
  "model": "/models/Qwen3-VL-30B-A3B-Instruct",  
  "choices": [  
    {  
      "index": 0,  
      "message": {  
        "role": "assistant",  
        "content": "你好！有什么我可以帮助你的吗？🌹"  
      },  
      "refusal": null,  
      "annotations": null,  
      "audio": null,  
      "function_calls": null,  
      "reasoning_content": null,  
      "logprobs": null,  
      "finish_reason": "stop",  
      "stop_reason": null,  
      "token_ids": null  
    }  
  ],  
  "service_tier": null,  
  "system_fingerprint": null,  
  "usage": {  
    "prompt_tokens": 9,  
    "total_tokens": 19,  
    "completion_tokens": 10,  
    "prompt_tokens_details": null,  
    "prompt_logprobs": null,  
    "prompt_token_ids": null,  
    "kv_transfer_params": null  
  }  
}  
[root@login1 ~]#
```

示例 2：PubChem 分子查询 API 代理

运行

```
python /public/software/profile.d/api_proxy.py \  
--target https://pubchem.ncbi.nlm.nih.gov &
```

```
(base) [ecnuhpc@login2 ~]$ python /public/software/profile.d/api_proxy.py \  
> --target https://pubchem.ncbi.nlm.nih.gov &  
[2] 73465  
(base) [ecnuhpc@login2 ~]$  
  
=====
```

■ 服务启动成功： None

🕒 目标接口： https://pubchem.ncbi.nlm.nih.gov

🌐 绑定网卡地址： http://10.11.100.254:5001

📖 【无感调用指南】

已开启完全无感模式，您可以直接在局域网其他主机上发起请求：

🕒 调用示例 (CURL)：

```
curl http://10.11.100.254:5001
```

```
[root@gpu4 ~]# curl -v http://10.11.100.254:5001
* About to connect() to 10.11.100.254 port 5001 (#0)
*   Trying 10.11.100.254...
* Connected to 10.11.100.254 (10.11.100.254) port 5001 (#0)
> GET / HTTP/1.1
> User-Agent: curl/7.29.0
> Host: 10.11.100.254:5001
> Accept: */*
< HTTP/1.1 200 OK
< Server: Werkzeug/3.1.7 Python/3.13.5
< Date: Tue, 24 Mar 2026 10:16:20 GMT
< Date: Tue, 24 Mar 2026 10:23:33 GMT
< Server: Apache
< Strict-Transport-Security: max-age=31536000; includeSubDomains; preload
< Referrer-Policy: origin-when-cross-origin
< Content-Security-Policy: upgrade-insecure-requests
< Last-Modified: Thu, 26 Feb 2026 19:28:57 GMT
< Accept-Ranges: bytes
```

示例 3：带 API Key 的上游接口代理

```
python /public/software/profile.d/api_proxy.py \
  --target https://api.openai.com/v1 \
  --api-key "sk-xxxxxx" \
  --auth-header "Authorization"
```

3.2 服务启动成功提示

启动后终端输出核心信息（直接复制访问命令即可）：

```
=====
✅ 服务启动成功: Qwen3-VL-30B-A3B-Instruct
🎯 目标接口: http://59.78.189.xxx:8888
📍 绑定地址: http://10.11.100.254:5000
=====
```

3.3 访问代理服务

唯一访问规则： `http://10.11.100.254:自动分配端口/接口路径`

无需任何额外参数，直接执行最简 curl 命令：

```
curl http://10.11.100.254:5000/v1/chat/completions \
  -H "Content-Type: application/json" \
  -d '{
    "model": "/models/Qwen3-VL-30B-A3B-Instruct",
    "messages": [{"role": "user", "content": "你好"}],
    "temperature": 0.7
  }'
```

```
[root@login1 ~]# curl http://10.11.100.254:5000/v1/models
{"object":"list","data":[{"id":"/models/Qwen3-VL-30B-A3B-Instruct","object":"model","created":1774347457,"owned_by":"vllm","root":"/models/Qwen3-VL-30B-A3B-Instruct","parent":null,"max_model_len":2047,"permission":[{"id":"modelperm-477f5a458a7840ae92350880a538ceae","object":"model_permission","created":1774347457,"allow_create_engine":false,"allow_sampling":true,"allow_logprobs":true,"allow_search_indices":false,"allow_view":true,"allow_fine_tuning":false,"organization":"**","group":null,"is_blocking":false}]}]}[root@login1 ~]#
[root@login1 ~]# curl http://10.11.100.254:5000/v1/chat/completions \
-H "Content-Type: application/json" \
-d '{
  "model": "/models/Qwen3-VL-30B-A3B-Instruct",
  "messages": [{"role": "user", "content": "你好"}],
  "temperature": 0.7
}'
{"id":"chatcmpl-4ff6797fe0042b08a295c1872c5b209","object":"chat.completion","created":1774347502,"model":"/models/Qwen3-VL-30B-A3B-Instruct","choices":[{"index":0,"message":{"role":"assistant","content":"你好！有什么我可以帮助你的吗？😊"},"refusal":null,"annotations":null,"audio":null,"function_calls":null,"tool_calls":[],"reasoning_content":null,"logprobs":null,"finish_reason":"stop","stop_reason":null,"token_ids":null},"service_tier":null,"system_fingerprint":null,"usage":{"prompt_tokens":9,"total_tokens":19,"completion_tokens":10,"prompt_tokens_details":null},"prompt_logprobs":null,"prompt_token_ids":null,"kv_transfer_params":null}[root@login1 ~]#
```

四、用户使用规范

为保障高性能计算中心服务稳定、安全、合规运行，所有用户必须遵守以下规范：

1. 合规使用原则

本代理服务仅限校内合法科研、教学业务使用，**严禁用于违法违规、商业盈利、网络攻击、数据爬取滥用等行为。**

2. 用户隔离义务

服务采用账号级隔离机制，**严禁盗用、冒用他人账号启动 / 访问服务**，严禁尝试绕过用户权限限制。

3. 端口与资源规范

- 仅使用系统自动分配的 5000~5010 端口，禁止手动占用、抢占他人端口；
- 长期闲置服务请及时关闭，避免占用集群端口与进程资源；
- 禁止批量启动大量代理服务造成资源滥用。

1. 网络与数据规范

- 禁止通过本服务传输涉密数据、敏感数据、违规内容；
- 调用外部 API 需遵守对应平台用户协议，不得违反接口调用限额与使用规则；
- 禁止对代理服务进行反向代理、二次转发，扩大访问范围。

1. 脚本修改规范

用户可根据自身模型接口修改脚本，但**不得修改安全校验、IP 绑定、用户隔离等核心权限逻辑**；修改后产生的运行问题自行负责，可联系管理员协助排查。

2. 日志与审计

中心保留所有代理服务访问日志，用于安全审计与故障排查，用户不得删除、篡改日志信息。

五、重要注意事项

1. 唯一访问入口

仅 `http://10.11.100.254`:端口 可访问服务，使用 `127.0.0.1` 或主机其他 IP 均会被系统拒绝。

2. 后台常驻建议

长期运行服务建议使用 `nohup` 后台启动，防止终端断开导致服务终止。

3. 接口路径兼容性

`--target` 填写 API 根地址即可，请勿重复拼接 `/v1` 等路径，避免出现 404 错误。

4. 故障处理

出现连接异常、代理报错时，可先重启服务；仍无法解决可发送日志至技术支持邮箱。

5. 服务可用性

本服务为科研辅助工具，中心不承诺 100% 不间断可用，会根据集群维护计划适时重启调整。

六、后台常驻运行（用完请及时回收）

```
# 后台启动并输出日志
nohup python /public/software/profile.d/api_proxy.py \
  --target http://59.78.189.xxx:8888 \
  --name "Qwen3-VL-30B" > proxy.log 2>&1 &

# 停止服务
ps -ef | grep proxy_server.py | grep -v grep
kill -9 <PID>
```

七、常见问题（FAQ）

1. 访问提示 Connection refused

仅支持 `10.11.100.254` 访问，请勿使用 `127.0.0.1` 等其他 IP。

2. 提示权限拒绝，仅归属用户可访问

当前 Linux 账号与服务启动账号不一致，切换至启动账号即可。

3. 启动提示端口全部占用

`5000~5010` 端口段已满，等待其他用户释放或联系管理员扩容。

4. 接口返回 404 Not Found

`--target` 地址与访问路径重复拼接（如已带 `/v1`），修正目标地址即可。

八、技术支持

如遇到脚本运行、权限配置、端口分配、代理异常等问题，可将：

- 报错日志
- 启动命令
- 访问命令

发送至技术支持邮箱：

zxtian@mail.ecnu.edu.cn

九、免责声明与最终解释权

1. 本服务为华东师范大学高性能计算中心提供的科研辅助工具，因用户自身使用不当、脚本修改、违规操作导致的一切后果，由用户自行承担。
2. 因集群维护、网络波动、上游接口故障等不可抗因素导致服务中断，中心不承担相关责任。
3. 华东师范大学高性能计算中心保留对本服务、使用规范、访问规则的最终解释权。
4. 中心有权根据集群运行与安全管理需要，随时调整服务配置、端口范围、使用策略，无需提前逐一通知用户。
5. 凡使用本服务即视为已阅读并同意本文档所有条款与规范。