

C6 扩散模型相关内容中文翻译

说明：本翻译覆盖课程 C6.pdf 中与扩散模型直接相关的部分，包括第 115-151 页的扩散模型与 score matching 主体，以及第 153-181 页的生物学应用案例。少数原页以图片或公式为主，文字抽取较少；此处保留页码，并对可见核心公式和文字作忠实翻译。

第 115 页：什么是扩散模型？

什么是扩散模型？——生成模型

旁注：人工智能领域排名前三的会议是 NeurIPS、ICML 和 ICLR。

第 116 页：生成模型的历史

生成模型的历史

VAE -> GAN -> Diffusion

VAE -> GAN -> Diffusion

这概括了生成模型的演化路径：从早期的变分方法，到对抗式训练，再到基于扩散的架构。每一类方法都在生成保真度、可控性和语义理解方面带来进一步提升。

第 117 页：文本到图像

文本到图像

本页主要展示文本生成图像的示例。

第 118 页：图像分辨率

图像分辨率

本页主要展示图像分辨率相关示例。

第 119 页：离散时间扩散模型

离散时间扩散模型

- 正向扩散过程 $q(x_t/x_{t-1})$ ：逐渐向图像中加入高斯噪声，直到最终得到纯噪声。
- 反向去噪扩散过程 $p_\theta(x_{t-1}/x_t)$ ：训练一个神经网络，使其能够从纯噪声开始，逐步对图像去噪，直到得到真实图像。

扩散模型由一系列增量更新组成，整体组合起来形成类似编码器-解码器的结构。

第 120 页：变分扩散模型

变分扩散模型

初始模块、过渡模块、最终模块。

第 121 页：正向过程

正向过程

我们将正向条件分布定义为高斯分布：

$$q_\phi(x_t/x_{t-1}) = N(x_t/\sqrt{\alpha_t}x_{t-1}, (1-\alpha_t)I)$$

从 x_0 到 x_T 的正向过程为：

$$q_\phi(x_{0:T}) = q(x_0) \prod_{t=1}^T q_\phi(x_t/x_{t-1})$$

并且：

$$q_\phi(x_t/x_0) = N(x_t/\sqrt{\alpha_t}x_0, (1-\alpha_t)I), \alpha_t = \prod_{i=1}^t \alpha_i$$

第 122 页：反向过程

反向过程

更有趣的部分是反向过程，它通过一系列去噪操作来实现。每一个去噪步骤都应该与正向过程中的对应步骤相耦合。我们试图得到 $p_{\theta}(x_{t-1}/x_t)$ ，这样就能从高斯噪声 x_T 生成图像 x_0 。然而， $p_{\theta}(x_{t-1}/x_t)$ 的显式形式不可得，因此我们可以用一个高斯分布来建模它，并尝试用神经网络学习其中的参数：

$$p_{\theta}(x_{0:T}) = p(x_T) \prod_{t=1}^T p_{\theta}(x_{t-1}/x_t)$$

在原始的 Denoising Diffusion Probabilistic Model (DDPM) 论文中，作者假设方差 Σ_{θ} 是固定的，只有 μ_{θ} 未知。在 improved DDPM 论文中，方差也被建模。

$$p_{\theta}(x_{t-1}/x_t) = N(x_{t-1} / \mu_{\theta}(x_t), \sigma_q^2(t) I)$$

如何学习这些参数？

第 123 页：证据下界

证据下界

训练试图最大化 x_0 的似然。

对于训练，可以构造变分上界，即负的 ELBO，这也是训练变分自编码器时常用的形式：

$$E_{q(x_0)}[-\log p_{\theta}(x_0)] \leq E_{q(x_0)q(x_{1:T}/x_0)} \left[-\log \frac{p_{\theta}(x_{0:T})}{q(x_{1:T}/x_0)} \right] = L$$

我们可以得到如下分解：ELBO 包含初始模块、最终模块和过渡模块对应的项。

挑战：

- 它并不是显式已知的。
- 即便假设其为高斯分布，我们仍然需要访问未来样本 x_{t+1} 才能抽取当前样本 x_t ，这在直觉上是反常的。

第 124 页：证据下界

贝叶斯技巧

从贝叶斯规则出发：

$$q(x_t/x_{t-1}) = \frac{q(x_{t-1}/x_t)q(x_t)}{q(x_{t-1})}$$

在给定 x_0 的条件下，可以写为：

$$q(x_{t-1}/x_t, x_0) = \frac{q(x_t/x_{t-1}, x_0)q(x_{t-1}/x_0)}{q(x_t/x_0)}$$

通过该技巧，变分扩散模型的 ELBO 可以等价地写成包含以下部分的形式：初始重构项、先验匹配项，以及新的逐步一致性项。

第 125 页：反向过程的分布

反向过程的分布

后验分布具有如下形式：

$$q_\phi(x_{t-1}/x_t, x_0) = N(x_{t-1} | \mu_q(x_t, x_0), \Sigma_q(t))$$

其中：

$$\begin{aligned} \mu_q(x_t, x_0) &= \frac{(1 - \alpha_t)\sqrt{\alpha_t}}{1 - \alpha_t} x_t + \frac{(1 - \alpha_t)\sqrt{\alpha_{t-1}}}{1 - \alpha_t} x_0 \\ \Sigma_q(t) &= \frac{(1 - \alpha_t)(1 - \alpha_{t-1})}{1 - \alpha_t} I \equiv \sigma_q^2(t) I \end{aligned}$$

其中：

$$\alpha_t = \prod_{i=1}^t \alpha_i$$

ELBO 可以简化为一个让模型均值 $\mu_\theta(x_t)$ 接近真实后验均值 $\mu_q(x_t, x_0)$ 的训练目标。

第 126 页：模型训练

L_{t-1} 是可处理项。由贝叶斯规则可得训练形式。

模型训练

本页主要展示从贝叶斯规则得到可训练目标的公式推导。

第 127 页：DDPM 中的扩散训练

DDPM 中的扩散训练

DDPM 训练中的正向扩散与模型训练示意。

第 128 页：DDPM 中的推理

DDPM 中的推理

本页展示 DDPM 从噪声开始逐步反向去噪生成样本的流程。

第 129 页：预测噪声

预测噪声

本页展示把模型训练目标转化为噪声预测任务的思路。

第 130 页：模型训练

因此，损失最小化退化为噪声预测任务，即最小化噪声预测的均方误差：

$$E_{x_0, t, \epsilon} \left[\left\| \epsilon - \epsilon_\theta(x_t, t) \right\|^2 \right]$$

在实践中，通常使用带时间编码的 U-Net 来构造 ϵ_θ 。

第 131 页：去噪扩散隐式模型（DDIM）

Denoising Diffusion Implicit Model（DDIM）

如果沿着反向扩散过程的马尔可夫链从 DDPM 中生成一个样本，速度会非常慢，因为 T 可以达到一千步或几千步。

DDPM 的转移分布定义为：

$$q(x_t / x_{t-1}) = N(x_t / \sqrt{\alpha_t} x_{t-1}, (1 - \alpha_t) I)$$

$$q(x_t / x_0) = N(x_t / \sqrt{\alpha_t} x_0, (1 - \alpha_t) I)$$

马尔可夫性质：

- 正向扩散过程是无记忆的。
- 每一步只依赖紧邻的上一步。
- 这可能导致收敛速度慢。

DDIM 重新定义转移分布，从而允许更快采样。

第 132 页：加速扩散模型采样

加速扩散模型采样

相关内容可以在 improved DDPM 论文中找到。

你将在作业中亲自尝试 DDIM。

第 133 页：条件扩散模型

条件扩散模型

前面介绍的模型都是无条件模型。我们无法控制生成过程，也无法指定想要的内容。例如，使用 ImageNet 训练的模型不能专门生成猫。

无条件模型通常用于探索生成模型的能力。若要构建对用户有用的产品，就必须让模型能够遵循指令，这就是条件扩散模型。

条件扩散模型一般可以分为两类：classifier guidance model 和 classifier-free model。

Classifier guidance 的预算较友好，因为它只需要一个预训练分类器，并且可以插入大公司训练好的无条件扩散模型。相反，classifier-free 方法需要重新训练整个扩散模型，但通常能提供更好的性能，因此被大公司采用。

第 134 页：条件扩散模型

条件扩散模型

本页主要展示条件扩散模型的结构或示意图。

第 135 页：分类器引导

Classifier Guidance

假设我们有一个分类器 $p_\phi(y/x_t)$ 。可以通过正向过程生成训练数据，也就是向 x_0 加噪声，来训练这个分类器。

我们可以使用该分类器引导扩散模型生成对应标签 y 的图像。

第 136 页：分类器引导

Classifier Guidance

使用贝叶斯规则。

加噪声不会显著影响分类，因此：

$$p_\phi(y/x_{t-1}) \approx p_\phi(y/x_{t-1}, x_t)$$

再应用泰勒展开，可以得到用于引导采样的表达式。

第 137 页：分类器引导

重写上一页的方程。对于无条件扩散模型，对比有条件形式可以看到，只需要额外加入一项。

在实践中，我们使用分类器对扩散模型生成的图像 x_t 进行分类，计算其属于目标类别 y 的概率。然后对 x_t 求梯度，并用该梯度引导反向采样过程。

第 138 页：无分类器引导

Classifier-Free

对于 classifier-free model，只需要应用贝叶斯定理来替换 classifier guidance 部分。

这样可以把条件与无条件形式合并起来。因此我们只需要实现一个 epsilon 网络，并在无标签时把 y 设为零或空条件。

第 139 页：视频生成

视频生成

本页主要展示视频生成示例。

第 140 页：自己尝试

Try Yourself

Hugging Face 上有许多扩散模型空间，自己尝试一下！

第 141 页：目录

目录页。后续进入 Score Matching。

第 142 页：Score-Matching Langevin Dynamics (SMLD)

Score-Matching Langevin Dynamics (SMLD)

为什么本章重要：它把优化式更新与真正的分布采样联系起来。

- 从分布中采样；
- Stein score function；
- Score matching 技术；
- 总结性说明。

核心问题：如果目标密度 $p(x)$ 未知，为了从中采样，我们需要什么量？

答案：一旦知道 score，Langevin dynamics 就能把迭代更新转化为采样器。

动机示例：给定分布 $p(x)$ ，我们希望从 $p(x)$ 中抽样。正常图像应该比异常图像具有更高概率。寻找更高概率可以转化为优化问题。不同于最大似然估计中数据固定而模型参数变化，这里模型参数固定，而数据点在变化。

第 143 页：从优化到 Langevin 采样

梯度上升会找到一个众数；Langevin dynamics 加入噪声，使过程能够从整个分布中采样。

先从最大化开始：对 log density 做梯度上升。这对于寻找高概率点有用，但它本身不能生成一个样本分布。

离散时间 Langevin 方程：

- 漂移项：推动点向更高密度区域移动。
- 噪声项：防止坍缩到单个点，并允许随机探索。
- 本章总结：Langevin equation = gradient descent + noise。

一维高斯混合直觉：梯度上升最终会到达一个峰；加入噪声后，序列会在峰附近移动，而不是只停在峰顶。因此，梯度上升终止于一个众数，而 Langevin dynamics 从分布中采样。

第 144 页：从优化到 Langevin 采样示例

继续考虑前面的高斯混合示例。

假设初始化 $M=10000$ 个均匀分布样本 $x_0 \sim Uniform[-3,3]$ ，运行 Langevin 更新 100 步。生成样本的直方图显示：初始样本均匀分布，随着时间推进，样本分布逐渐变成目标分布。

第 145 页：为什么 Langevin Dynamics 合理？

Fokker-Planck 视角解释了为什么目标密度会成为平稳分布。

Fokker-Planck 方程定理：

- 随机变量 x_t 具有随时间变化的密度 $p(x, t)$ 。
- 如果把目标密度 $p(x)$ 代入方程右侧，则在平稳状态下 PDE 变为零。
- 因此，目标密度就是 Langevin 过程的平稳分布。

Stein score function：

- score 在样本空间中定义一个向量场。
- 在 $\log p(x)$ 变化最大的地方，向量最强；在峰值附近较弱。
- 数据点大致沿箭头向某个 basin 移动，而噪声保持运动的随机性。

第 146 页：主要困难

SMLD 通过学习 score 的神经近似，并将其代入 Langevin dynamics 来解决问题。

未知量：目标密度 $p(x)$ 不可访问，因此精确 score 也不可访问。

学习神经 score 模型：直接从样本训练 s_θ ，而不是显式建模归一化密度。

训练后的采样递推：实际 SMLD 流程是先学习 score，再通过随机更新采样。

一页总结：

训练样本来自数据分布 $\rightarrow$ 训练 score 网络 $s_\theta(x)$ $\rightarrow$ 将 score 代入 Langevin 更新 $\rightarrow$ 从噪声生成样本。

本章比较了三条路线：explicit score matching、implicit score matching 和 denoising score matching (DSM)。后续定理解释了为什么 DSM 是最可解释、最实用的路线。

第 147 页：定理与两条经典路线：ESM vs. ISM

显式 score matching 先估计一个替代密度；隐式 score matching 避免 KDE，但引入 Jacobian trace。

显式 score matching (ESM) 的思想：用 kernel density estimate $q_h(x)$ 近似未知密度 $p(x)$ 。

ESM 的特点：

- 概念上简单：先估计替代密度，再匹配其 score。
- 课程指出的弱点：KDE 在高维和样本有限时表现很差。
- 训练后，用 $s_\theta(x)$ 替换 Langevin dynamics 中的真实 score。

隐式 score matching (ISM)：

- 不需要显式密度估计。
- 但 trace / Jacobian 项对于深度神经网络可能代价很高。
- 因此课程引出更实用的替代方案：DSM。

第 148 页：去噪 Score Matching (DSM)

DSM 用“已知的扰动模型”替代“估计未知密度”，把 score 学习转化为去噪。

高斯扰动模型：

$$\tilde{x} = x + \sigma z, z \sim N(0, I)$$

目标 score 来自已知的条件扰动分布。

实用 DSM 损失：

- 网络输入：带噪样本 $x + \sigma z$ 。
- 目标：负噪声方向 $-z / \sigma$ 。
- 因此，score 学习变成去噪任务。

直白解释：

- 预测噪声等价于去噪，因为去噪图像加上预测噪声就能得到带噪观测。因此，定理中的方程就是一个去噪步骤。
- 带噪样本被推离数据流形；学到的 score 告诉我们如何回到高密度区域。
- 这就是课程强调“预测噪声等价于去噪”的原因。
- 从概念上看，DSM 是从前面章节通向后续扩散式训练目标的最清晰桥梁。

第 149 页：为什么 DSM 合法？

Vincent 的等价定理解释了为什么去噪损失可以估计与显式 score matching 相同的 score function，差别只在一个与 θ 无关的常数。

这个定理带来的意义：

- DSM 不只是一个启发式去噪技巧。
- 它通过目标等价结果，在理论上与 score matching 联系起来。
- 因此，我们获得了更可解释、更实用的损失，同时不改变学习到的最优解。

三条路线比较：

ESM :

- 估计 KDE 替代密度 ;
- 概念简单 ;
- 高维下弱。

ISM :

- 不需要 KDE ;
- 使用 Jacobian trace ;
- 通常难以扩展。

DSM :

- 使用已知扰动模型 ;
- 具有可解释的去噪目标 ;
- 是本章中最实用的方法。

第 150 页：训练与推理

score matching 模型的训练过程通常通过最小化 denoising score matching 损失函数完成。

训练过程：Song 和 Ermon 提出的 noise conditioned score network (NCSN)。

其中单个损失函数根据噪声等级 $\sigma_1, \dots, \sigma_L$ 定义。

推理：

- 假设我们已经训练好了 score estimator s_θ 。为了生成图像，使用 Langevin 方程，通过迭代去噪来抽取样本。
- 其中步长控制每次更新幅度， $s_\theta(x_t, \sigma_i)$ 表示噪声等级 σ_i 下的 score matching 函数。

训练 s_θ :

- 假设固定噪声等级 σ 。
- 网络 s_θ 被训练为估计噪声。

第 151 页：总结

一个紧凑的故事线：学习 score，然后通过随机更新采样。

一条流程：

目标密度未知 $\rightarrow$ 需要 score $\nabla_x \log p(x) \rightarrow$ 学习 score $s_\theta(x) \rightarrow$ 运行 Langevin 更新 $\rightarrow$ 得到来自 $p(x)$ 的样本。

三个值得明确说出的要点：

- Fokker-Planck 相关定理解释了 Langevin dynamics 为什么与目标分布相连。
- score function 是核心量，因为它决定漂移方向。
- DSM 是最适合讲解的结果：它把 score 学习转化为去噪。

与后续扩散模型的联系：

- 它是概念基础，而不是最终的工业算法。
- 保留下来的关键思想是：学习 score，并用随机更新生成数据。
- 因此它自然连接到 score-based models 和 diffusion models。

第 153 页：扩散模型能为生物研究做什么？

这是一个简短的幻灯片组，说明扩散模型在哪些地方最有帮助：图像、单细胞 / 多组学、分子设计和患者层面的模拟。

生成、去噪、补全、条件化。

核心思想：扩散模型学习如何反转结构化噪声。在生物学中，这很自然地转化为真实数据生成、缺失数据补全、模态转换和具有不确定性意识的预测。

最佳使用场景：高维、噪声大、多模态、条件生成、稀疏观测。

生物测量含有噪声：显微成像、MRI、CT、测序和从 EHR 得到的特征都含有结构化噪声。扩散模型正是被训练来反转小的噪声增量。

缺失很常见：缺失模态、缺失基因、稀疏 peak 和不完整图像都很常见。条件去噪天然支持插补和补全。

生物学是多尺度的：细胞状态、组织、器官和分子跨层级相互作用。扩散模型可以以标签、协变量、时间或结构为条件。

有用的心智模型：扩散模型不只是图像生成器。在生物学中，它通常更适合被看作复杂科学对象的灵活条件采样器：图像、细胞、分子或患者轨迹。

第 154 页：生物医学影像

生物医学影像：扩散模型已经最强的地方

图像恢复：

- 低剂量 CT、加速 MRI 和噪声显微图像的去噪；
- 超分辨率、去模糊、运动校正和图像修补。

跨模态转换：

- MRI -> CT、缺失 contrast 的合成、扫描仪 harmonization；
- 当某个模态昂贵、有风险或不可用时非常有用。

数据增强：

- 生成真实的稀有病灶、病理或组织学模式；
- 如果经过谨慎验证，可以提高鲁棒性。

主要收益：当任务本身就像去噪或逆重建时，扩散模型特别有吸引力：从退化观测出发，迭代恢复一个合理的干净对象。

注意：视觉真实感不够。在生物影像中，评估还必须检查解剖结构、生物标志物、校准性以及跨中心泛化。

代表性任务：重建、分割辅助、合成、harmonization、不确定性感知恢复。

第 155 页：MRI 图像生成

MRI 图像生成

本页主要展示 MRI 图像生成示例。

第 156 页：MRI 图像重建

MRI 图像重建

本页主要展示 MRI 图像重建示例。

第 157 页：单细胞与多组学

单细胞和多组学：生成、插补、轨迹

合成细胞：

- 为稀缺细胞类型生成真实的 scRNA-seq profiles ；
- 可用于增强、基准测试和稀有状态发现。

缺失数据补全：

- 插补基因、染色质可及性或蛋白丰度；
- 在配对或部分配对设计中补全缺失模态。

连续轨迹：

- 以拟时序或协变量为条件，建模发育和扰动路径；
- 有助于细胞状态层面的 what-if 模拟。

为什么在生物学上重要：单细胞数据稀疏、组成性强且高度异质，正适合条件生成建模；这种建模既能揭示平滑的潜在结构，又能保留多模态性。

良好的评价目标：细胞类型保真度、稀有细胞覆盖、轨迹平滑性、差异信号保留。

第 158 页：药物发现与蛋白设计

小分子：

- 在口袋几何或靶点约束条件下生成新配体；
- 在保持三维合理性的同时优化理化性质。

蛋白质和肽：

- 在结构指导下设计骨架、序列或治疗性肽；
- 可用于 de novo 设计和结构条件生成。

对接 / 相互作用：

- 在约束下建模蛋白-配体或蛋白-蛋白构型；
- 可能成为从生成设计到可测试候选物的桥梁。

真正的机会：扩散模型可以从化学和结构上有效的设计空间中采样，并明确以功能、结构、分类或靶点上下文为条件。

瓶颈：不只是生成。评分、可合成性、稳定性和实验验证仍然决定设计是否真正有意义。

第 159 页：生物研究中的底线

扩散模型最有帮助的地方：

1. 影像中的噪声逆问题；
2. 稀疏、多模态的单细胞和组学场景；
3. 条件分子和蛋白设计。

需要注意：

- 真实感之外的生物学有效性；
- 泄漏、隐私和队列偏差；
- 计算成本和评估难度；
- 需要湿实验或外部验证。

如果科学问题可以表述为“在约束下生成 / 重建 / 补全一个复杂生物对象”，扩散模型通常是一个强候选模型。

第 160 页：跨模态图像合成

Cross-Modality Image Synthesis

Y. Pan, M. Liu 等，MICCAI 2018；IEEE Transactions on Medical Imaging 2020；IEEE TPAMI 2022。

通过深度学习进行跨模态图像合成。

第 161 页：用于诊断的跨模态图像合成

完整多模态图像下的诊断：MRI、PET、标签。

不完整多模态图像下的诊断：

- 用于疾病诊断的多模态影像数据，例如 MRI 和 PET；
- 提供脑部互补信息；
- 受试者通常存在不完整的多模态数据。

第 162 页：跨模态图像合成

合成 PET、合成 MRI、真实 PET、真实 MRI。

目标：为诊断生成缺失的 PET/MRI 扫描。

第 163 页：合成 PET 扫描

展示合成 PET 扫描示例，并与 GAN、CGAN、VGAN、本文方法和 ground truth 比较。

PSNR：峰值信噪比。

第 164 页：多模态分类

用于分类的 landmark-based multi-scale network。

第 165 页：实验

展示 pMCI vs. sMCI 在完整 MRI 和 PET，以及插补后数据上的实验结果。

第 166 页：基于扩散的图像合成

M. Yu, M. Wu, L. Yue, A. Bozoki, and M. Liu. Medical Image Analysis, 2026。

M. Yu, M. Liu. ISMRM, 2024。

基于扩散的图像合成：用于 MRI-to-PET 图像合成的图像约束扩散。

第 167 页：用于 PET 合成的深度去噪扩散

生成 PET scans from MRI。

训练阶段：正向扩散过程。

生成式反向去噪过程：从噪声逐步生成 PET。

推理阶段：使用 3D MRI 作为条件输入，生成合成 PET。

第 168 页：用于 PET 合成的深度去噪扩散

训练阶段包括：

- 正向扩散过程；
- 条件扩散模型；
- 噪声等级约束；
- 图像级约束；
- 时间步编码；
- 通过网络逐步得到 x_{t-1} 和估计的干净 PET。

第 169 页：合成 FDG-PET 扫描

展示 CycleGAN、VAEGAN、DDPM、FICD 等方法与真实 PET 的比较。

PSNR：峰值信噪比。

第 170 页：合成 FDG-PET 扫描差异图

展示 FICD、LDM、DDPM、VAEGAN、VAE、CycleGAN、GAN 与真实 MRI / 真实 PET 的轴向视图差异图比较。

第 171 页：泛化到 Amyloid-PET 合成

在 AIBL 上合成 Amyloid PET。

进行 NFL-LONG 上的跨 tracer PET 合成。

注：PBR 指 translocator protein (TSPO) tracer。

第 172 页：生成的 PET SUVR Maps

合成 Centiloid Project 中 PiB-PET 的 standardized uptake value ratio (SUVR)。

Centiloid scale：AD 受试者约为 100.9 ± 5.8 ；年轻对照约为 1.5 ± 5.0 。

$CL \geq 50$ 与 AD 强相关； $CL < 10$ 可较可靠地指示没有神经炎性斑块，即排除 AD。

第 173 页：通过潜在扩散改善输出唯一性

改善输出唯一性——**Latent Diffusion**

在潜在空间中进行扩散。

将图像映射到低维潜在空间后，高频且不可感知的细节会被抽象掉，从而减少重建图像中的多样性。

第 174 页：泛化到 Amyloid-PET 合成

展示将所提出的 FICD fine-tune 到 AIBL cohort 中，从不同 radiotracer 的图像合成 Amyloid PET 的结果。

第 175 页：改善输出唯一性

展示同一受试者通过八次独立采样生成的合成 PET 图像，比较 DDPM 与 FICD。每次采样都引入新的随机噪声。

采样过程中引入的噪声会导致随机波动。

第 176 页：使用生成式 AI 框架 DNA-Diffusion 设计合成调控元件

使用 **DNA-Diffusion** 设计合成调控元件

第 177 页：动机与目标

目标：设计约 200 bp 的短 DNA 调控元件，使其在选定细胞类型中具有活性。

挑战：

- DNA 很容易生成，但功能性 enhancer 需要正确的转录因子 motif “语法”；
- 需要平衡新颖性、生物真实感和细胞类型特异性。

贡献：

- 一个条件扩散模型 “DNA-Diffusion”，训练于细胞类型特异性的开放染色质 (DHS) 序列；
- 然后通过 in silico selection 和湿实验验证寻找强且特异的 enhancer。

应用：

- 依赖上下文的合成 DNA 序列，例如细胞类型、染色质、转录因子环境；
- 细胞类型特异性编辑 / 靶向；
- 治疗性表达微调。

第 178 页：训练数据

训练数据：来自 DHS peaks 的 200 bp DNA 片段。

- 来自不同细胞类型的 unique DNase I hypersensitive sites DNA 序列，包括 K562、HepG2 和 GM12878。
- 对每个细胞类型，取 DHS summit 附近的 200 bp。

训练 / 验证 / 测试划分：

- 按染色体划分，例如留出某些染色体用于验证 / 测试。

生成：

- 每个细胞类型生成 100,000 条合成 200 bp 序列，共 300,000 条。

评价生成序列：

In silico validation：

- ChromBPNet，可及性；
- MPRA predictor，报告基因活性；
- Enformer，DNase + CAGE expression tracks。

湿实验验证：

- STARR-seq library，包含 5,850 个元素，覆盖 3 个细胞系，episomal reporter assay；
- EXTRA-seq endogenous locus experiment：替换 AXIN2 附近 enhancer 区域并测量再激活。

第 179 页：DNA 序列的条件扩散

扩散模型：

- DDPM 学习 $p(x/y)$ ，即给定细胞类型 y 时 DNA 序列 x 的分布。

去噪器输入：

- 带噪序列 x_t ；
- 扩散时间步 t ；
- 细胞类型标签 y 。

架构：

- 在 (4×200) 的 one-hot-like DNA tensor 上使用 denoising U-Net ；
- 通过 timestep embedding 和 cell-type embedding 加入条件。

训练目标（核心方程）：

加噪：

$$x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon$$

训练网络预测噪声：

$$\min_{\theta} E \left\| \epsilon - \epsilon_{\theta}(x_t, t, y) \right\|^2$$

第 180 页：Classifier-Free Guidance：控制特异性与多样性

Classifier-Free Guidance (CFG)

训练过程中，以一定概率（约 10%）将细胞类型 y 替换为空 token：

- 条件形式： $\epsilon_{\theta}(x_t, t, y)$ ；
- 无条件形式： $\epsilon_{\theta}(x_t, t, \emptyset)$ 。

这会迫使模型同时学习两者。

采样时的 CFG：

计算：

$$\epsilon_{\text{cond}} = \epsilon_{\theta}(x_t, t, y), \epsilon_{\text{uncond}} = \epsilon_{\theta}(x_t, t, \emptyset)$$

组合：

$$\epsilon_{\text{CFG}} = \epsilon_{\text{uncond}} + s(\epsilon_{\text{cond}} - \epsilon_{\text{uncond}})$$

- s 是 guidance scale。
- 更大的 s 会更强地把样本推向目标细胞类型分布，即更高特异性、更低多样性。

第 181 页：实验结果

评价指标：

- 新颖性：生成的 200 bp 序列中，与训练 DHS 存在长精确匹配的比例；
- motif 真实感：TF motif 和 motif-pair 分布的相似性，例如 Jensen-Shannon distance；
- 信号强度：预测的调控信号有多强，例如 accessibility 或 CAGE level；
- 信号特异性：信号在多大程度上限制于目标细胞类型，而不是在所有细胞类型中都存在。

In silico validation：

- motif grammar：关键 TF motifs 是否适当富集？
- 预测式“oracles”，即 sequence -> function proxy：
- 染色质可及性预测器；
- MPRA / enhancer activity 预测器；
- Enformer-like 多轨道预测器。

湿实验验证：

- STARR-seq：序列是否在目标细胞类型中驱动转录？
- Endogenous locus test：设计序列是否能在基因组上下文中工作？