

C6 扩散模型讲解版

基于课程文件：C6.pdf，重点覆盖第 115-151 页的 Diffusion Models 与 Score Matching，并补充第 153-181 页的生物医学应用脉络。

1. 一句话理解扩散模型

扩散模型是一类“先把真实数据逐步加噪声，再学习如何一步步去噪声”的生成模型。

如果用图像来想象：训练时，我们把一张真实图像 x_0 逐渐变成纯噪声 x_T ；生成时，从一团高斯噪声 x_T 出发，模型一步一步预测并移除噪声，最后得到一张看起来像训练数据的新图像 x_0 。

这个思想的关键不在于“一次生成”，而在于“很多个小步骤累积”。每一步只解决一个相对简单的问题：当前图像里有多少噪声？该往哪里稍微修正？

2. 生成模型的历史位置：VAE -> GAN -> Diffusion

课程把生成模型的发展概括为：

$$\text{VAE} \rightarrow \text{GAN} \rightarrow \text{Diffusion}$$

这不是说扩散模型完全替代了前两者，而是说它在许多任务上取得了更好的稳定性、质量和可控性。

VAE 的优点是有明确的概率建模和潜变量结构，训练稳定，但样本常偏模糊。GAN 能生成锐利逼真的图像，但训练不稳定，容易出现模式坍塌。扩散模型训练通常更稳定，生成质量高，也更容易与文本、类别、图像等条件结合；代价是采样步骤多，计算较慢。

3. 正向扩散：把数据慢慢变成噪声

正向过程是人为设定的，不需要学习。它从真实数据 x_0 出发，逐步加入高斯噪声：

$$q(x_t/x_{t-1}) = N(x_t; \sqrt{\alpha_t}x_{t-1}, (1-\alpha_t)I)$$

其中 α_t 控制第 t 步保留多少原信号， $1-\alpha_t$ 控制加入多少噪声。经过很多步以后， x_T 近似服从标准高斯分布：

$$x_T \sim N(0, I)$$

为了训练方便，我们常使用一个闭式表达，直接从 x_0 采样任意时刻的 x_t ：

$$q(x_t/x_0) = N(x_t; \sqrt{\alpha_t}x_0, (1-\alpha_t)I)$$

其中：

$$\alpha_t = \prod_{i=1}^t \alpha_i$$

等价地，可以写成更适合实现的形式：

$$x_t = \sqrt{\alpha_t}x_0 + \sqrt{1-\alpha_t}\epsilon, \epsilon \sim N(0, I)$$

这条公式非常重要。它告诉我们：任意噪声等级下的样本 x_t ，都可以由干净样本 x_0 和一份高斯噪声 ϵ 直接构造出来。

4. 反向去噪：模型真正要学的部分

生成时我们要做相反的事情：

$$x_T \rightarrow x_{T-1} \rightarrow \cdots \rightarrow x_0$$

反向过程写作：

$$p_\theta(x_{t-1}/x_t)$$

问题是，真实的反向条件分布无法直接得到。DDPM 的做法是把每一步反向分布也建模为高斯分布：

$$p_\theta(x_{t-1}/x_t) = N(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(t))$$

原始 DDPM 通常固定方差，主要学习均值；改进版 DDPM 也可以学习方差。直观上，神经网络在每个时间步接收带噪样本 x_t 和时间步 t ，输出“该怎么去噪”。

5. 为什么最后变成“预测噪声”？

课程第 123-130 页从 ELBO 出发推导训练目标。核心结论是：虽然理论上是在最大化数据似然、匹配反向高斯分布，但实际训练可以简化为一个很直观的任务：

$$L_{simple}(\theta) = E_{x_0, t, \epsilon} [\|\epsilon - \epsilon_{\theta}(x_t, t)\|^2]$$

也就是说，网络 ϵ_{θ} 的目标不是直接输出最终图像，而是预测加入到 x_0 里的噪声 ϵ 。

为什么这有效？因为如果知道当前样本 x_t 中的噪声成分，就能反推出更干净的方向。预测噪声等价于告诉模型：“这个点偏离数据流形的方向是什么？应该往哪边回去？”

6. U-Net 与时间编码

课程提到实际中常用带时间编码的 U-Net 来构造噪声预测网络：

$$\epsilon_{\theta}(x_t, t)$$

U-Net 适合图像任务，因为它同时保留局部细节和全局结构。时间编码则告诉模型当前噪声等级。例如 $t=900$ 时图像几乎是噪声，模型应做粗略结构恢复； $t=50$ 时图像已较清晰，模型应更关注细节修复。

没有时间编码，模型无法区分“轻微噪声”和“严重噪声”，训练会混乱。

7. DDPM 的采样流程

训练完成后，DDPM 的生成过程如下：

1. 从标准高斯噪声采样 $x_T \sim N(0, I)$ 。
2. 对 $t=T, T-1, \dots, 1$ 反复执行去噪。
3. 每一步用 $\epsilon_{\theta}(x_t, t)$ 估计噪声，并构造 x_{t-1} 。
4. 最后得到样本 x_0 。

伪代码可以写成：

```
x_T ~ N(0, I)
for t = T, T-1, ..., 1:
    eps = epsilon_theta(x_t, t)
```

```
x_{t-1} = denoise(x_t, eps, t)
return x_0
```

DDPM 的优势是稳定、质量高；缺点是如果 T 是 1000 步，生成一次就要运行网络 1000 次，采样很慢。

8. DDIM：为什么能加速？

DDIM 的动机是：DDPM 反向采样沿着马尔可夫链逐步走，步数可能很大。DDIM 通过重新设计转移过程，使采样可以跳步，并且在一定条件下保持与 DDPM 相同的边缘分布。

课程强调 DDPM 的马尔可夫性质：

- 正向扩散过程无记忆。
- 每一步只依赖上一步。
- 这会导致采样收敛慢。

DDIM 不是简单“少走几步”，而是利用同一个 x_t 与 x_0 关系，构造更直接的路径。因此它可以用更少步数生成样本，常用于扩散模型加速。

9. 条件扩散：让模型听指令

无条件扩散模型只能从训练分布里随机生成。例如在 ImageNet 上训练，它可能生成动物、车辆、物体，但不能保证“我要猫”。

条件扩散模型学习：

$$p_{\theta}(x/y)$$

其中 y 可以是类别、文本、MRI 图像、细胞类型、蛋白结构约束等。课程把条件扩散分为两类：

- Classifier guidance：使用一个额外分类器 $p_{\phi}(y/x_t)$ 引导采样。
- Classifier-free guidance：训练同一个模型同时学有条件和无条件预测，采样时组合二者。

9.1 Classifier Guidance

假设有分类器：

$$p_{\phi}(y/x_t)$$

在采样时，它告诉模型当前带噪样本 x_t 有多像目标类别 y 。我们对 x_t 求梯度：

$$\nabla_{x_t} \log p_{\phi}(y/x_t)$$

这个梯度可以作为引导方向，使反向采样更倾向生成目标类别。

9.2 Classifier-Free Guidance

Classifier-free guidance 不需要额外训练分类器，而是在训练时随机把一部分条件 y 替换为空条件 $\emptyset$ ，让同一个网络同时学会：

$$\epsilon_{\theta}(x_t, t, y)$$

和：

$$\epsilon_{\theta}(x_t, t, \emptyset)$$

采样时组合两者：

$$\epsilon_{\text{CFG}} = \epsilon_{\text{uncond}} + s(\epsilon_{\text{cond}} - \epsilon_{\text{uncond}})$$

s 是 guidance scale。 s 越大，样本越贴近条件，但多样性可能下降； s 太小，模型可能不够听指令。

10. Score Matching 与 Langevin Dynamics 的关系

课程第 142-151 页把扩散模型与 score-based generative modeling 联系起来。

score function 指的是：

$$\nabla_x \log p(x)$$

它是数据空间中的一个向量场，指向概率密度上升最快的方向。直觉上，如果一个点偏离真实数据分布，score 会告诉它“往哪里走更像真实数据”。

Langevin dynamics 的离散形式可以理解为：

$$x_{t+1} = x_t + \eta \nabla_x \log p(x_t) + \sqrt{2\eta} z_t, z_t \sim N(0, I)$$

其中第一项让点往高密度区域移动，第二项加入随机性，避免所有点都坍缩到一个模式。
课程概括为：

Langevin equation = gradient descent/ascent + noise

真正困难在于：真实数据分布 $p(x)$ 不可直接访问，所以 score $\nabla_x \log p(x)$ 也不可直接计算。SMLD 的做法是训练神经网络 $s_\theta(x)$ 去近似 score，然后把它放进 Langevin 更新中采样。

11. Denoising Score Matching：为什么“去噪”就是学 score？

课程给出三条路线：

- Explicit Score Matching：先估计密度，再匹配 score；高维下 KDE 很弱。
- Implicit Score Matching：不显式估计密度，但涉及 Jacobian trace，神经网络中代价高。
- Denoising Score Matching：使用已知加噪模型，把 score 学习变成去噪任务。

DSM 的关键直觉是：我们知道如何把干净样本加噪：

$$\tilde{x} = x + \sigma z, z \sim N(0, I)$$

因此网络可以学习把带噪样本 $\tilde{x}$ 拉回干净数据附近。课程中的目标可理解为：网络输入 $x + \sigma z$ ，目标方向是 $-z/\sigma$ 。这就把“估计未知密度的梯度”变成了“预测噪声方向”。

这也是 DDPM 中预测噪声目标的概念基础。

12. 生物医学应用：扩散模型不只是生成图片

课程第 153 页以后强调，扩散模型在生物医学中更像一个“复杂科学对象的条件采样器”，对象可以是图像、细胞、多组学数据、分子、蛋白质或患者轨迹。

最适合扩散模型的问题通常具有这些特点：

- 高维；
- 噪声大；
- 多模态；
- 需要条件生成；
- 观测稀疏或存在缺失。

12.1 医学影像

扩散模型特别适合影像恢复和逆问题：

- 低剂量 CT 去噪；
- 加速 MRI 重建；
- 显微图像去噪；
- 超分辨率；
- 去模糊；
- 运动校正；
- 图像修补；
- MRI 到 CT、MRI 到 PET 等跨模态合成。

但课程也提醒：医学影像不能只看“像不像”。还必须检查解剖结构、生物标志物、校准性和跨中心泛化能力。

12.2 MRI-to-PET 合成

课程展示了用条件扩散从 MRI 合成 PET 的例子。这里 MRI 是条件输入，PET 是目标输出。模型训练时对真实 PET 加噪，并学习在 MRI 条件下反向去噪，推理时从噪声出发生成合成 PET。

这类任务的价值在于：PET 昂贵、有辐射且不总是可用；如果能从 MRI 合成具有诊断价值的 PET，就可以缓解多模态缺失问题。不过合成结果必须经过定量指标、临床相关指标和外部数据验证。

12.3 单细胞与多组学

单细胞数据稀疏、异质、多模态，适合条件生成和缺失补全：

- 生成稀有细胞类型的合成 scRNA-seq profile；
- 补全基因、染色质可及性或蛋白丰度；
- 进行跨模态补全；
- 按拟时序或扰动条件模拟细胞状态轨迹。

评价时不能只看分布相似，还要看细胞类型保真度、稀有细胞覆盖、轨迹平滑性和差异信号是否保留。

12.4 药物发现与蛋白设计

扩散模型可用于在结构约束下生成小分子、蛋白骨架、序列或相互作用构象。真正难点不只是“能生成”，还包括可合成性、稳定性、亲和力、毒性、实验可验证性等。

12.5 DNA-Diffusion

课程最后展示了 DNA-Diffusion：目标是设计约 200 bp 的 DNA 调控元件，使其在特定细胞类型中活跃。

模型学习：

$$p(x/y)$$

其中 x 是 DNA 序列， y 是细胞类型。输入包括带噪序列 x_t 、时间步 t 、细胞类型标签 y 。训练目标仍然是预测噪声：

$$\min_{\theta} E \left\| \epsilon - \epsilon_{\theta}(x_t, t, y) \right\|^2$$

这说明扩散模型的核心思想不仅适用于图像，也适用于 one-hot DNA 序列、分子结构等离散或结构化科学对象。

13. 学习时最容易卡住的点

第一，正向过程不是模型学出来的，而是人为定义的加噪过程。

第二，反向过程才是模型要学的去噪过程。

第三，DDPM 训练时常见目标是预测噪声，而不是直接预测干净图像。

第四，时间步 t 很重要；同一张带噪图像在不同噪声等级下需要不同去噪策略。

第五，条件扩散的本质是让采样分布从 $p(x)$ 变成 $p(x/y)$ 。

第六，score matching 解释了为什么“预测噪声/去噪”能和“沿数据分布高密度方向移动”联系起来。

14. 最小知识地图

如果只记一张图，可以这样串：

真实数据 x_0

|

| 正向扩散 q ：逐步加高斯噪声

v

纯噪声 x_T

|

| 反向过程 p_θ ：神经网络逐步去噪

v

新生成样本 x_0

训练时：

x_0 + 随机噪声 ϵ + 随机时间 $t \rightarrow x_t$

网络输入： x_t , t , 条件 y

网络输出： 预测噪声 ϵ_θ

损失： $\|\epsilon - \epsilon_\theta\|^2$

采样时：

从 $x_T \sim N(0, I)$ 开始

反复用 ϵ_θ 去噪

得到新样本

15. 课程对应页码

- 第 115-119 页：扩散模型是什么、从 VAE/GAN 到 Diffusion、离散时间扩散。
- 第 120-130 页：变分扩散、正向过程、反向过程、ELBO、DDPM 训练与噪声预测。
- 第 131-132 页：DDIM 与采样加速。
- 第 133-138 页：条件扩散、classifier guidance、classifier-free guidance。
- 第 142-151 页：Score Matching、Langevin Dynamics、DSM。
- 第 153-181 页：扩散模型在生物医学影像、单细胞/多组学、药物/蛋白设计、DNA-Diffusion 中的应用。