

G2 数据生成与质量控制实施方案

生成日期：2026-05-18

项目目录： /Users/hwaigc/比赛+课题/ECNU-NYU2026

目标任务：BraTS 2026 Challenge Task 1, Brain Metastases Segmentation

对应分工：G2，数据生成与质量控制

主要读者：G2 本人、G1 核心开发同学、S1/S2 nnU-Net 分割组、其他分割模型组成员

0. 结论先行

G2 的核心不是“把 G1 的模型多跑几遍”，而是把生成模型变成能被分割组可靠使用的数据工程系统。完整闭环应为：

真实数据清点

- > corrected labels 覆盖
- > 与 G1 定义生成输出契约
- > 批量合成 raw cases
- > manifest 追踪
- > 基础 QC / label QC / 图像 QC / 多模态一致性 QC
- > 转 nnU-Net v2 imagesTr + labelsTr
- > 教师分割模型一致性筛查
- > 真实验证集下游消融
- > 质量报告与下一轮生成建议

G2 第一阶段建议采用“离线合成数据集”为主：先让合成病例落盘，经过 QC，再交给 S1/S2 训练。on-the-fly 生成或动态插入肿瘤可以作为第二阶段增强路线，先不要在第一轮把系统复杂度拉满。

最终判断合成数据是否有用的标准不是 FID、MS-SSIM 是否好看，而是固定真实验证划分上：

- 真实训练数据 vs 真实训练数据 + 合成数据；
- Dice、NSD、病灶检测 F1/AUC 是否改善；
- 小病灶召回是否提升；
- 假阳性是否可控；
- 对 NETC、SNFH、ET、RC 四类是否有稳定帮助。

1. 背景与 G2 目标

1.1 任务背景

BraTS 2026 Task 1 是 Brain Metastases Segmentation，即脑转移瘤分割与检测任务。参赛算法需要自动检测并精确分割不同大小的脑转移瘤，覆盖治疗前和治疗后病例。

官方 Task 1 使用四标签体系：

标签	缩写	含义	G2 需要关注的生成约束
0	background	背景	不应把脑外区域误生成病灶
1	NETC	非强化肿瘤核心	通常应在 ET 或肿瘤核心结构内出现，不能大量孤立漂浮
2	SNFH	周围非强化 FLAIR 高信号	与 FLAIR/T2W 强信号应一致，边界不应过硬
3	ET	强化肿瘤	T1C 上应有明显增强表现，是检测核心之一
4	RC	切除腔	主要见于治疗后病例，生成时要避免医学上不合理的孤立空腔

2026 年 Task 1 还强调 lesion-wise detection。小病灶尤其重要：官方文档提到小于 27 mm^3 的小病灶具有临床相关性；分割指标只应用于大于 275 mm^3 的病灶，但检测指标需要关注每一个独立病灶。

这意味着 G2 不能沿用“删掉所有小连通域以提高 Dice”的粗暴策略。对 MET 来说，小连通域可能是目标，不一定是噪声。

1.2 G2 的目标

G2 负责把 G1 训练好的扩散模型输出转化为可训练、可追踪、可评估的合成数据资产。具体目标如下：

1. 接收 G1 的模型或推理接口，批量生成合成病例。
2. 开发自动化脚本，把合成病例转换为 nnU-Net v2 的 `imagesTr + labelsTr` 格式。
3. 建立数据 manifest，记录每个合成病例的来源、模型版本、随机种子、标签来源、QC 结果。
4. 建立合成数据 QC 流程，剔除格式错误、标签非法、图像异常、图像标签不一致、多模态不一致的样本。
5. 建立质量评估体系，包含 FID、MS-SSIM、医学特征距离、教师模型一致性和真实验证集消融。
6. 给 S 组交付可复现的合成数据集、固定训练划分、QC 报告和消融结论。

1.3 G2 不应做的事

- 不应只生成图片展示，不交付可训练 NIfTI 数据。
- 不应把合成数据直接混入真实训练集而不记录来源。
- 不应把 validation 病例派生出的合成样本放进 training。
- 不应把 FID/MS-SSIM 当成最终质量结论。
- 不应静默修正非法 label。所有修正必须记录规则和病例 ID。
- 不应让 G1 的输出格式“自由发挥”。必须先锁定数据契约。

2. 本地数据盘点与官方 corrected-labels 处理

2.1 本地数据结构

当前本地目录：

```
2026的task1以及数据/  
  BraTS2026_Task1_中文.md  
  BraTS2026_Task1_English.md  
  G2_数据生成与质量控制实现难度评估.md  
  MICCAI-LH-BraTS2025-MET-Challenge-TrainingData_batch1.zip  
  MICCAI-LH-BraTS2025-MET-Challenge-Training/  
  MICCAI-LH-BraTS2025-MET-Challenge-ValidationData_batch1.zip  
  Validation/  
  MICCAI-LH-BraTS2025-MET-Challenge-corrected-labels_batch1.zip  
  MICCAI-LH-BraTS2025-MET-Challenge-corrected-labels/
```

当前扫描结果：

数据	本地状态	病例数	文件结构
Training batch1	已解压	1296 个带标签病例	每例 t1n/t1c/t2w/t2f/seg
Training 顶层病例	已解压	650 个	直接位于 Training 根目录下
UCSD - Training	已解压	646 个	位于 Training 子目录内
Validation batch1	已解压	179 个无公开标签病例	每例 t1n/t1c/t2w/t2f
corrected-labels	已解压	2 个 label 文件	用于覆盖训练集中对应原 mask

训练集病例路径示例：

MICCAI-LH-BraTS2025-MET-Challenge-Training/

BraTS-MET-00001-000/

BraTS-MET-00001-000-t1n.nii.gz

BraTS-MET-00001-000-t1c.nii.gz

BraTS-MET-00001-000-t2w.nii.gz

BraTS-MET-00001-000-t2f.nii.gz

BraTS-MET-00001-000-seg.nii.gz

UCSD - Training/

BraTS-MET-01085-003/

BraTS-MET-01085-003-t1n.nii.gz

BraTS-MET-01085-003-t1c.nii.gz

BraTS-MET-01085-003-t2w.nii.gz

BraTS-MET-01085-003-t2f.nii.gz

BraTS-MET-01085-003-seg.nii.gz

2.2 数据规模与官方文档差异

Task 文档中提到训练集总数为 1496，其中包含 200 个 Ulm 未标注病例。本地当前可直接用于监督训练的带标签训练病例为 1296 个，正好等于 $1496 - 200$ 。因此本文档后续默认：

- 监督训练、合成标签统计、真实 label 分布基线：使用本地 1296 个带标签病例；
- 未标注 Ulm 病例：当前本地未见，暂不纳入第一阶段；
- 如果后续官方发布新 batch，需要重新运行 manifest 和 QC。

2.3 shape、spacing 与 dtype 现状

训练集和验证集均为混合空间数据，不是所有病例都已统一到 $240 \times 240 \times 155$ 。

训练集扫描结果：

- 1296 个病例均具备 4 模态和 seg。
- 每个病例内部的 shape 与 spacing 一致。
- 跨病例 shape/spacing 差异很大。
- image dtype 包含 int16、float32、float64 等。
- label dtype 也不统一，包含 uint16、float32、float64 等。

验证集扫描结果：

- 179 个病例均具备 4 模态。
- 每个病例内部 4 模态 shape 与 spacing 一致。
- 常见 shape 包括 $240 \times 240 \times 155$ 、 $256 \times 256 \times 376$ 、 $512 \times 512 \times 176$ 、 $512 \times 512 \times 372$ 等。

G2 的脚本必须基于 NIfTI header 和 affine 工作，不能写死固定 shape。转换 nnU-Net 时也不应提前手动 resample，优先让 nnU-Net planner/preprocessor 处理 spacing 差异。

2.4 corrected-labels 必须覆盖原 mask

Synapse 官方讨论说明：

- 2026 MET Batch 1 数据集与 2025 版本一致；
- 官方计划稍后发布新 batch，因此文件名中带有 _batchX 后缀；
- corrected-labels 文件夹中的 segmentation masks 是最终修正版本；
- 需要手动用 corrected labels 替换训练集中的原始 masks。

官方讨论链接：<https://www.synapse.org/Synapse%3Asyn74274097/discussion/threadId%3D12731>

本地 corrected labels：

```
MICCAI-LH-BraTS2025-MET-Challenge-corrected-labels/  
BraTS-MET-01094-003-seg.nii.gz  
BraTS-MET-01184-002-seg.nii.gz
```

处理规则：

1. 在开始任何训练、统计、QC、nnU-Net 转换之前，先应用 corrected labels。
2. 根据文件名寻找训练集中同名病例目录。
3. 将原始 *-seg.nii.gz 备份或在 manifest 中记录原始路径与 corrected 路径。
4. 转换和 QC 时使用 corrected 版本作为最终标签。
5. 报告中记录 corrected label 应用清单。

推荐不要直接覆盖原始数据目录。更稳妥做法是建立一个“逻辑覆盖层”：

```
manifest 中记录：  
case_id=BraTS-MET-01184-002  
raw_seg_path=.../Training/UCSD - Training/BraTS-MET-01184-002/BraTS-MET-01184-002-seg.n  
effective_seg_path=.../corrected-labels/BraTS-MET-01184-002-seg.nii.gz  
label_source=corrected
```

2.5 本地额外发现的 label 风险

全训练集 label 值扫描发现：

```
global_values: [0.0, 1.0, 2.0, 3.0, 4, 6, 8]
cases_with_label:
  label 1: 698 cases
  label 2: 1148 cases
  label 3: 1250 cases
  label 4: 167 cases
bad_count: 2
UCSD - Training/BraTS-MET-01094-002 contains label value 6
UCSD - Training/BraTS-MET-01184-002 contains label value 8
```

其中 BraTS-MET-01184-002 有 corrected label, 可通过官方 corrected 文件修正到 {0,1,2,3,4}。但 BraTS-MET-01094-002 含非法值 6, 当前 corrected 包中给的是 BraTS-MET-01094-003, 不是 01094-002。

G2 第一版脚本必须把 01094-002 标为高风险病例, 处理方式不能静默决定。推荐策略:

- 默认在 g2_build_manifest.py 中将其标为
qc_pass=false、qc_reason=illegal_label_value_6;
- 暂不纳入第一轮 nnU-Net 训练;
- 向组织方或队内负责人确认该病例是否应映射 6 -> ?;
- 如果后续确认规则, 必须在 label_fix_rules.yaml 中记录, 并在报告中说明。

3. 往年冠军代码可复用点

本项目已有往年代码目录:

```
往年文章和code/
2023/
2025/
```

G2 不需要逐行复现往年代码, 但应理解其设计思想, 并把可复用逻辑改造成 2026 MET 数据适配版本。

3.1 2023/2024 GliGAN: 标签生成、ROI 插入、metadata、affine/header 保存

核心路径:

往年文章和code/2023/Segmentation_Tasks/GliGAN/src/
train/csv_creator.py
train/label_main.py
train/tumour_main.py
infer/main_random_label_random_dataset_generator_multiprocess.py
utils/data_utils.py
utils/convert_to_multi_channel_based_on_brats_classes.py

GliGAN 方案不是凭空生成完整 MRI，而是：

1. 从真实病例中读取四模态和 label。
2. 生成或抽取一个肿瘤 label patch。
3. 找到一个在脑内、远离原有肿瘤、不会越界的位置。
4. 把 label patch 插入原始 segmentation。
5. 对四个 MRI 模态分别使用生成器补出对应 ROI。
6. 保存合成病例，并尽量继承原图 affine/header。

G2 可复用思想：

- csv_creator.py：为真实病例统计病灶中心、bbox、尺寸，生成训练/插入索引。
- main_random_label_random_dataset_generator_multiprocess.py：批量生成逻辑、start_case/end_case 分片、每例生成多个 synthetic cases。
- save_nifti()：保存 NIFTI 时继承参考图像 header/affine。
- random_center_tumour_voxel() 和插入逻辑：避免把新病灶放到脑外或原病灶区域。
- 生成 metadata：记录每个样本由真实 label 还是合成 label 产生。

G2 需要改的地方：

- 旧代码面向 glioma，标签组合和 region 定义不同，不能直接复用 label mapping。
- 旧代码常用 t1/t1ce/t2/flair 命名，2026 数据使用 t1n/t1c/t2w/t2f。
- 旧代码假设很多数据是 240x240x155 或 patch 96^3，2026 MET native space shape 差异更大。
- 旧代码的 postprocessing 阈值不能照搬，因为 2026 Task 1 强调小病灶检测。

3.2 3D WDM：局部 inpainting、条件 mask、wavelet channel、ROI 强度校正

核心路径：

往年文章和code/2023/Synthesis/Task8/
data_creator/run_data_creator.py
data_creator/utils/data_creator_utils.py
wdm-3d/run.sh
wdm-3d/guided_diffusion/c_bratsloader.py
wdm-3d/scripts/c_generation_train.py
wdm-3d/scripts/c_generation_sample.py
testing/inference.py

WDM 方案适合 G1 的扩散模型参考。核心思路：

- 训练阶段：输入 t1n 、 mask_healthy 、 mask_unhealthy 等字段。
- 采样阶段：输入 t1n_voided + mask ，只在 mask ROI 内加噪和生成。
- 使用 3D Haar wavelet，把 1 个体数据分为 8 个 wavelet channels。
- 条件模型常见设置为 in_channels=16 、 out_channels=8 。
- 采样后用 IDWT 还原，再只替换 ROI，背景保留真实图像。
- 通过线性校正使生成区域强度与周围真实组织更连续。

G2 可复用思想：

- 对 MET 生成，优先采用局部插入/局部 inpainting，而不是从零生成整脑。
- 已知区域保持真实，只生成病灶 ROI，能降低解剖结构崩坏风险。
- G2 QC 应重点检查 ROI 边界强度连续性。
- 如果 G1 是 2D 或 2.5D 模型，G2 要额外做 3D 连贯性检查。

G2 需要改的地方：

- Task8 主要是 T1n inpainting，而 2026 需要四模态共同一致。
- G1 若只生成单模态，需要明确其他模态从哪里来。
- WDM 采样步数很大，示例中 3000-5000 steps，非常慢；G2 批量调度必须支持断点续跑。

3.3 2025 on-the-fly 增强：动态插入肿瘤、类别与小病灶控制

本地论文：

往年文章和code/2025/2025年第一名.pdf

2025 成人胶质瘤第一名方案的关键思想：

- 不预先保存海量 synthetic NIfTI，而是在 nnU-Net 训练 batch 中动态插入合成肿瘤。
- 对小病灶和低频类别进行定向增强。

- 保持验证集只含真实病例。
- 训练 baseline、regular on-the-fly、custom on-the-fly，再 ensemble。

G2 可复用思想：

- 第一阶段先做离线 synthetic dataset，便于调试和质控。
- 第二阶段如果离线数据太占空间或生成质量稳定，可以把插入逻辑迁移到 nnU-Net dataloader。
- 对 2026 MET，custom augmentation 重点应放在：
 - 小于 27 mm³ 的检测相关病灶；
 - 27–275 mm³ 的小病灶；
 - 多发病灶病例；
 - 稀有 RC 标签；
 - ET/NETC/SNFH 的合理组合。

3.4 BraTS Orchestrator: MET 教师模型/质量裁判候选

核心路径：

往年文章和code/2025/

brats/core/segmentation_algorithms.py

brats/data/meta/metastases.yml

metastases.yml 中列出 2025 和 2023 Brain Metastases 任务的顶尖算法容器，例如：

- brainles/brats25_met_gli-team:latest
- brainles/brats25_met_weskrikorian:latest
- brainles/brats23_met_nvauto:latest

G2 可复用方式：

- 如果本机 Docker/GPU 可用，可用这些模型对 synthetic MRI 跑分割。
- 将 teacher prediction 与 synthetic label 对比，筛掉明显不一致的样本。
- 如果 Docker/GPU 不可用，先用 S1 的 nnU-Net baseline 作为 teacher。

注意：teacher model 不是 ground truth。它只能辅助发现明显异常，不能替代下游真实验证集消融。

4. G1-G2 对接契约

G1 和 G2 必须先锁定接口，否则后续脚本会不断返工。建议把以下契约放进队内共享文档或 README_G1_G2_CONTRACT.md 。

4.1 G1 最低交付内容

G1 至少要向 G2 提供：

项目	必需性	说明
模型 checkpoint	必需	路径、版本号、训练数据范围、训练日期
推理脚本或命令	必需	能从命令行批量生成病例
环境说明	必需	Python 版本、PyTorch、MONAI、CUDA、依赖安装方式
输入格式	必需	接收原始病例目录、mask、label、seed 还是 JSON list
输出格式	必需	四模态 + seg + metadata.json
生成模式	必需	full-case、local-insertion、slice-stitching、2D、2.5D、3D
随机种子控制	必需	同一 seed 能否复现同一结果
失败返回规范	必需	无可插入位置、OOM、空输出、非法标签时如何记录
推理性能	建议	单病例耗时、显存、CPU/RAM、推荐 batch size

4.2 G1 输出目录契约

G1 输出的 raw synthetic case 必须采用稳定结构：

```
synthetic_raw/  
  run_YYYYMMDD_HHMM_modelname/  
    SYN-MET-000001/  
      SYN-MET-000001-t1n.nii.gz  
      SYN-MET-000001-t1c.nii.gz  
      SYN-MET-000001-t2w.nii.gz  
      SYN-MET-000001-t2f.nii.gz  
      SYN-MET-000001-seg.nii.gz  
      metadata.json  
    SYN-MET-000002/  
      ...  
  generation_log.jsonl
```

命名规则：

- 合成病例 ID 使用 SYN-MET-000001 递增。

- 不要复用真实病例 ID 作为合成病例 ID。
- 如果是从真实病例派生，在 `metadata.json` 中记录 `source_case_id`。
- 文件名必须和目录名一致。
- 模态后缀必须为 `t1n/t1c/t2w/t2f/seg`。

4.3 G1 输出 NIfTI 契约

每个合成病例必须满足：

- 四模态和 `seg` 均为 `.nii.gz`。
- 四模态和 `seg` 的 `shape` 一致。
- 四模态和 `seg` 的 `spacing` 一致。
- `affine` 应与 `source case` 或目标空间一致。
- `header` 应可由 `nibabel` 或 `SimpleITK` 正常读取。
- 图像中不允许有 `NaN/Inf`。
- `seg` 必须是整数标签，值域只能是 `{0,1,2,3,4}`。
- 如果允许空 `mask`，必须在 `metadata` 中显式标记 `allow_empty_mask=true`；否则默认空 `mask` 拒绝。

4.4 metadata.json schema

建议每个合成病例包含如下 `metadata`：

```
{
  "schema_version": "g2.synthetic.case.v1",
  "case_id": "SYN-MET-000001",
  "source_case_id": "BraTS-MET-00001-000",
  "source_case_path": ".../BraTS-MET-00001-000",
  "generator_name": "G1_conditional_ldm",
  "generator_checkpoint": ".../checkpoints/epoch_120.pt",
  "generator_git_commit": "unknown",
  "generation_run_id": "run_20260518_2100_g1_ldm_v1",
  "generation_mode": "local_insertion",
  "model_dimensionality": "2.5D",
  "seed": 42,
  "label_source": "synthetic_label",
  "label_strategy": "insert_new_lesion_to_non_tumor_brain_region",
  "modalities": ["t1n", "t1c", "t2w", "t2f"],
  "shape": [256, 256, 160],
  "spacing": [1.0, 1.0, 1.0],
  "affine_source": "source_case",
  "labels_present": [0, 2, 3],
  "lesion_count": 2,
  "label_volumes_mm3": {
    "NETC": 0,
    "SNFH": 1350,
    "ET": 220,
    "RC": 0
  },
  "roi_bbox_ijk": [80, 130, 95, 145, 40, 70],
  "qc_status": "not_run",
  "qc_reject_reason": null
}
```

G2 可以在 QC 后追加字段：

```
{
  "g2_qc_version": "v1",
  "g2_qc_status": "accepted",
  "g2_qc_reasons": [],
  "teacher_model": "S1_nnunet_baseline_fold0",
  "teacher_label_dice": 0.74,
  "accepted_for_training": true
}
```

4.5 G1 推理命令契约

G1 最好提供一个命令行接口：

```
python g1_infer.py \  
  --input-manifest manifests/real_train_manifest.csv \  
  --output-dir synthetic_raw/run_20260518_g1_v1 \  
  --checkpoint checkpoints/g1_model.pt \  
  --num-synthetic 300 \  
  --cases-per-source 1 \  
  --seed 42 \  
  --start-index 0 \  
  --end-index 300 \  
  --device cuda:0
```

最低要求：

- 同一命令可重复运行。
- 已完成病例不重复生成，或支持 `--overwrite false`。
- 中断后可继续。
- 每个失败病例写入 `generation_log.jsonl`。
- 不把异常吞掉。

5. G2 批量生成流程

5.1 推荐目录结构

G2 工作目录建议如下：

```
G2_outputs/  
  manifests/  
    real_train_manifest.csv  
    real_validation_manifest.csv  
    corrected_label_overlay.csv  
    synthetic_candidate_manifest.csv  
    synthetic_accepted_manifest.csv  
    synthetic_rejected_manifest.csv  
  synthetic_raw/  
    run_20260518_g1_v1/  
      SYN-MET-000001/  
      SYN-MET-000002/  
      generation_log.jsonl  
  qc/  
    qc_metrics.csv  
    lesion_distribution_real.csv  
    lesion_distribution_synthetic.csv  
  figures/  
    real_vs_synth_volume_hist.png  
    qc_reject_reasons.png  
    montage_accepted/  
    montage_rejected/  
  nnunet_raw/  
    Dataset260_BraTS2026_MET_RealOnly/  
    Dataset261_BraTS2026_MET_RealSynth025/  
    Dataset262_BraTS2026_MET_RealSynth050/  
  splits/  
    splits_final_fold0_realval.json  
  reports/  
    G2_synthetic_data_quality_report.md
```

5.2 阶段 A：真实数据 manifest

先扫描真实训练集和验证集，建立 manifest。不要一开始就直接转 nnU-Net。

real_train_manifest.csv 字段：

case_id
split_source
case_dir
t1n_path
t1c_path
t2w_path
t2f_path
raw_seg_path
effective_seg_path
label_source
shape
spacing
affine_hash
image_dtypes
label_dtype
labels_present
has_illegal_label
illegal_label_values
has_corrected_label
qc_pass
qc_reason

其中：

- split_source 可为 batch1_top_level 或 ucsd_training 。
- raw_seg_path 指向原训练集 label。
- effective_seg_path 若存在 corrected label，则指向 corrected 文件；否则等于 raw_seg_path 。
- qc_pass=false 的病例不进入第一轮训练。

5.3 阶段 B：应用 corrected labels

推荐脚本： g2_apply_corrected_labels.py

该脚本不一定物理覆盖原数据，也可以只生成 overlay manifest。

输入：

```
--train-root 2026的task1以及数据/MICCAI-LH-BraTS2025-MET-Challenge-Training
--corrected-dir 2026的task1以及数据/MICCAI-LH-BraTS2025-MET-Challenge-corrected-labels
--manifest-in G2_outputs/manifests/real_train_manifest_raw.csv
--manifest-out G2_outputs/manifests/real_train_manifest.csv
```

输出：

```
corrected_label_overlay.csv
real_train_manifest.csv
```

corrected_label_overlay.csv 字段：

```
case_id
raw_seg_path
corrected_seg_path
raw_unique_labels
corrected_unique_labels
applied
notes
```

处理逻辑：

1. 遍历 corrected label 文件。
2. 根据文件名解析 case_id 。
3. 在训练集递归查找同名病例。
4. 校验 shape/spacing 是否与原病例一致。
5. 在 manifest 中把 effective_seg_path 指向 corrected label。
6. 不存在匹配病例则报错，不静默跳过。

5.4 阶段 C：批量调用 G1

推荐脚本： g2_generate_batch.py

G2 不直接写死 G1 的模型内部逻辑，而是封装调用 G1 推理命令。脚本负责：

- 切分病例范围；
- 控制 seed；
- 调度 GPU；
- 跳过已完成病例；
- 合并 generation_log.jsonl ；

- 初步检查输出文件是否齐全。

输入：

```
--real-manifest G2_outputs/manifests/real_train_manifest.csv
--g1-command-template configs/g1_infer_template.yaml
--output-dir G2_outputs/synthetic_raw/run_20260518_g1_v1
--num-synthetic 300
--cases-per-source 1
--seed 42
--device cuda:0
```

输出：

```
synthetic_raw/run_xxx/
synthetic_candidate_manifest.csv
generation_log.jsonl
```

第一轮建议只生成 20 个 smoke cases：

目标：验证 G1-G2 接口、NIfTI 输出、QC、nnU-Net 转换能跑通。
不追求质量，不做大规模训练。

第二轮生成 100-300 个候选病例：

目标：跑完整 QC 与一折消融。

第三轮再扩展到更大规模。

5.5 阶段 D：候选 synthetic manifest

synthetic_candidate_manifest.csv 字段：

```
synthetic_case_id
source_case_id
generation_run_id
generator_checkpoint
seed
case_dir
t1n_path
t1c_path
t2w_path
t2f_path
seg_path
metadata_path
shape
spacing
affine_hash
labels_present
generation_mode
model_dimensionality
qc_pass
qc_reasons
accepted_for_training
```

manifest 的意义是每个合成样本都可追溯。后续如果 S1/S2 训练结果下降，可以按 checkpoint、生成策略、病灶体积分布、来源病例回溯问题。

6. nnU-Net v2 自动转换方案

6.1 输出格式

nnU-Net v2 raw dataset 推荐格式：

```
Dataset261_BraTS2026_MET_RealSynth025/
  imagesTr/
    BraTSMET_000001_0000.nii.gz
    BraTSMET_000001_0001.nii.gz
    BraTSMET_000001_0002.nii.gz
    BraTSMET_000001_0003.nii.gz
  labelsTr/
    BraTSMET_000001.nii.gz
dataset.json
```

通道顺序固定：

nnU-Net suffix	模态	原始文件后缀
_0000	T1 native	t1n
_0001	T1 contrast	t1c
_0002	T2 weighted	t2w
_0003	FLAIR	t2f

label 保持官方值域：

- 0 background
- 1 NETC
- 2 SNFH
- 3 ET
- 4 RC

不要照搬旧 glioma 代码里对标签 1/2 的交换逻辑。2026 MET 必须以 Task 1 文档为准。

6.2 dataset.json

基础版本：

```
{
  "channel_names": {
    "0": "t1n",
    "1": "t1c",
    "2": "t2w",
    "3": "t2f"
  },
  "labels": {
    "background": 0,
    "NETC": 1,
    "SNFH": 2,
    "ET": 3,
    "RC": 4
  },
  "numTraining": 0,
  "file_ending": ".nii.gz"
}
```

如果 S1/S2 决定使用 region-based training, 可另建版本, 但不要在 G2 第一版默认启用。region 版本需要和 S1/S2 确认:

```
{
  "labels": {
    "background": 0,
    "whole abnormal": [1, 2, 3, 4],
    "lesion core": [1, 3, 4],
    "enhancing tumor": 3,
    "resection cavity": 4
  },
  "regions_class_order": [1, 2, 3, 4]
}
```

6.3 转换脚本

推荐脚本: `g2_convert_to_nnunet.py`

输入:

```
--real-manifest G2_outputs/manifests/real_train_manifest.csv
--synthetic-manifest G2_outputs/manifests/synthetic_accepted_manifest.csv
--output-root G2_outputs/nnunet_raw/Dataset261_BraTS2026_MET_RealSynth025
--synthetic-ratio 0.25
--channel-order t1n,t1c,t2w,t2f
```

输出：

```
imagesTr/
labelsTr/
dataset.json
conversion_manifest.csv
```

转换逻辑：

1. 读取 real manifest 中 `qc_pass=true` 的真实病例。
2. 读取 synthetic accepted manifest 中 `accepted_for_training=true` 的合成病例。
3. 根据 `synthetic-ratio` 采样合成病例。
4. 为每个病例分配 nnU-Net ID，例如 `BraTSMET_000001`。
5. 复制或软链接四模态到 `imagesTr`。
6. 复制 label 到 `labelsTr`。
7. 生成 `dataset.json`。
8. 生成 `conversion_manifest.csv`，记录原始 `case_id` 到 nnU-Net `case_id` 的映射。

建议第一版使用复制，避免软链接在 Docker/远程服务器上路径失效。数据很大时可再改为硬链接或软链接。

6.4 转换前强制检查

每个病例转换前必须检查：

- 四模态和 label 是否存在。
- 四模态和 label shape 是否一致。
- 四模态和 label spacing 是否一致。
- label unique values 是否属于 `{0,1,2,3,4}`。
- 图像是否有 NaN/Inf。
- label 是否全空。
- affine 是否可读且非奇异。
- 对 synthetic case，是否有 metadata。

失败时：

- 不转换该病例；
- 写入 `conversion_manifest.csv` ；
- 写明 `skip_reason` ；
- 不让 nnU-Net 在后续阶段才暴露错误。

6.5 固定验证划分

G2 必须和 S1/S2 固定一个真实验证 fold。原则：

- validation fold 只能包含真实病例。
- synthetic case 只能进入 training fold。
- 如果 synthetic case 派生自某个真实 source case，该 source case 如果在 validation fold，则派生 synthetic case 也不能进入 training。

推荐 `splits_final_fold0_realval.json`：

```
[
  {
    "train": ["BraTSMET_000001", "BraTSMET_000002"],
    "val": ["BraTSMET_000101", "BraTSMET_000102"]
  }
]
```

其中 `val` 只包含真实病例。合成病例的 source lineage 必须通过 manifest 检查，避免数据泄漏。

7. 合成数据质量控制方案

7.1 QC 总体分层

G2 的 QC 分为四层：

- L0 文件格式 QC
- L1 label 几何 QC
- L2 图像质量与多模态一致性 QC
- L3 teacher/downstream validation QC

第一轮必须完成 L0/L1。L2 建议在 100-300 个候选样本阶段完成。L3 需要 S1/S2 baseline 或 BraTS orchestrator 支持。

7.2 L0: 硬性拒绝 QC

硬性拒绝条件：

- 缺少任一模态或 label。
- 任一 NIfTI 文件无法读取。
- 四模态和 label shape 不一致。
- 四模态和 label spacing 不一致。
- affine/header 不可读或明显异常。
- 图像含 NaN/Inf。
- label 含非法值，不属于 $\{0,1,2,3,4\}$ 。
- label dtype 是浮点但包含非整数值。
- label 全空且 metadata 未明确允许空 mask。
- synthetic case 缺少 metadata.json。

L0 输出：

```
qc_pass
qc_reasons
missing_files
shape
spacing
affine_hash
labels_present
illegal_label_values
```

7.3 L1: label 几何 QC

G2 需要计算 connected components。建议按“病灶集合”而不是单一 label 计算：

```
lesion_mask = (seg == 1) | (seg == 3) | (seg == 4)
```

原因：官方 detection 分支把 lesion 定义为 ET、NETC、RC 的集合性术语；SNFH 更像病灶周围区域，不应单独当作 lesion core。

需要统计：

- n_lesions
- 每个 lesion 体积，单位 mm^3
- $<27 \text{ mm}^3$ lesion 数量

- 27-275 mm³ lesion 数量
- >275 mm³ lesion 数量
- 每个 lesion 的 bbox
- lesion 是否接触脑外背景
- lesion 是否完全在非零脑区内
- 每类标签体积
- 每类标签出现频率

拒绝或警告规则：

情况	默认处理
lesion 完全在脑外	reject
lesion bbox 越界	reject
label 全空	reject，除非显式允许
超大 lesion 占据大面积脑区	warn/review
过多极小孤立点	reject 或 warn，取决于生成目标
NETC/RC 孤立远离 ET/lesion core	warn/review
SNFH 与任何 lesion core 完全不接触	warn/review

注意：不能简单删除所有小于某阈值的 connected components，因为 2026 强调小病灶检测。小病灶应先标记为类别，而不是默认删除。

7.4 L2：图像质量 QC

每个模态统计：

- 非零脑区 voxel 数。
- p0.5/p1/p50/p99/p99.5 强度分位数。
- 均值、标准差。
- 是否存在极端异常值。
- synthetic 与 source 的非 ROI 区域差异。
- ROI 内外边界强度跃迁。

ROI 边界检查：

1. 取 lesion mask 的 dilation shell。

2. 计算 shell 内外强度差。
3. 对每个模态分别统计。
4. 如果边界差异远高于真实训练集分布，标记为 `roi_boundary_artifact`。

多模态一致性检查：

- ET 区域在 T1C 应有相对增强。
- SNFH 区域在 FLAIR/T2W 应有高信号趋势。
- RC 区域不应表现得像实性增强肿瘤。
- 同一个 lesion 的 bbox 在四模态中不应出现明显错位。

这些检查第一版可以先输出 warn，不直接 reject；等积累人工抽查经验后再设阈值。

7.5 人工抽查

自动 QC 不能替代人工查看。每轮生成至少抽查：

- 20 个 accepted synthetic cases。
- 20 个 rejected synthetic cases。
- 所有包含 RC 的 synthetic cases 中抽样。
- 所有小于 27 mm³ lesion 的 synthetic cases 中抽样。
- teacher 模型预测与 synthetic label 差异最大的病例。

建议生成 montage：

```
t1n / t1c / t2w / t2f / seg overlay  
axial / coronal / sagittal  
source vs synthetic
```

8. FID、MS-SSIM 与医学特征评估

8.1 指标定位

FID、MS-SSIM 是辅助指标，只用于回答：

- synthetic 是否过于单一；
- synthetic 是否和 real 分布明显偏离；
- synthetic 是否近似复制 source case；
- 不同 G1 checkpoint 哪个更稳定。

它们不能单独证明合成数据有用。最终有效性必须看真实验证集消融。

8.2 FID 推荐实现

不建议直接使用 ImageNet Inception FID 评价 3D MRI。推荐三个层级：

快速版：2D slice feature FID

输入：

- 从每个病例抽取 lesion bbox 附近的 axial slices；
- 四模态可作为 4 channel，或分别计算；
- 使用医学图像预训练 2D encoder 或临时 CNN feature。

优点：

- 实现快；
- 可快速比较 checkpoint。

缺点：

- 忽略 3D 连续性；
- 对 MRI 医学真实性解释有限。

推荐版：nnU-Net encoder feature FID

使用 S1 baseline 或预训练 nnU-Net 的 encoder bottleneck feature：

```
real cases -> encoder features -> mean/cov  
synthetic cases -> encoder features -> mean/cov  
FID(real, synthetic)
```

优点：

- 特征与分割任务更相关；
- 比 ImageNet feature 更合理。

缺点：

- 依赖分割模型；
- 需要统一 patch/spacing 处理。

高级版：3D MedicalNet/SwinUNETR feature FID

使用医学 3D encoder 提取 case-level 或 lesion-level feature。适合作为最终报告补充，不建议第一周就投入太多时间。

8.3 MS-SSIM 推荐实现

MS-SSIM 用于评估多样性和近重复。

建议计算三类：

1. real-real MS-SSIM：真实数据内部相似度基线。
2. synthetic-synthetic MS-SSIM：合成数据内部相似度。
3. source-synthetic MS-SSIM：合成病例与其来源病例相似度。

解释：

- synthetic-synthetic 过高：可能模式坍塌。
- source-synthetic 过高：可能只是复制原图，没有有效新增信息。
- real-synthetic 过低：可能 synthetic 分布偏离真实。
- MS-SSIM 过低不一定好，可能是生成伪影。

建议只在 ROI 附近 patch 上计算，不要被大面积相同背景稀释。

8.4 医学分布指标优先于通用图像指标

对 G2 更有价值的指标：

- lesion count 分布；
- lesion volume 分布；
- 小病灶比例；
- label class frequency；
- ET 在 T1C 的强度对比；
- SNFH 在 FLAIR/T2W 的强度对比；
- teacher model lesion recall；
- 真实验证集 F1/NSD/Dice 改善。

9. 预训练/教师分割模型间接评估

9.1 teacher model 的作用

teacher model 用于发现“图像和标签明显不一致”的 synthetic case。

流程：

```
synthetic MRI
-> teacher segmenter
-> teacher prediction
-> compare with synthetic label
-> produce teacher consistency score
-> accept / warn / reject
```

9.2 可选 teacher

优先级：

- 1. S1/S2 训练出的 nnU-Net baseline fold0。
- 2. BraTS orchestrator 中的 2025 MET 容器。
- 3. BraTS orchestrator 中的 2023 MET 容器。

如果 Docker/GPU 环境暂时不可用，先用 S1 baseline。

9.3 teacher consistency 指标

计算：

- label-wise Dice：NETC、SNFH、ET、RC。
- region-wise Dice：lesion core (NETC|ET|RC)、whole abnormal (NETC|SNFH|ET|RC)。
- lesion-wise recall。
- lesion count difference。
- teacher prediction 是否完全漏掉 synthetic lesion。
- teacher 是否在 synthetic label 外产生大量 FP。

默认筛选建议：

情况	处理
teacher 完全漏掉大于 275 mm^3 的 ET/RC lesion	reject 或人工复核

情况	处理
teacher 与 synthetic label Dice 很低，但人工看图合理	keep with warning
teacher 产生大量 label 外 FP	warning
小于 27 mm ³ lesion 被 teacher 漏掉	不直接 reject，记录 small lesion recall

teacher 模型有偏差，不能把 teacher 当真值。它是 QC 辅助工具，不是最终裁判。

10. 下游消融实验设计

10.1 目标

下游消融回答唯一核心问题：

合成数据是否提升真实验证集上的分割和检测表现？

10.2 固定实验设置

和 S1/S2 约定：

- 固定 fold。
- 固定真实 validation。
- validation 中不包含 synthetic case。
- synthetic case 不从 validation source case 派生。
- 同一 nnU-Net 配置。
- 同一 preprocessing。
- 同一训练 epoch/iteration。
- 同一 postprocessing。

10.3 推荐第一轮实验矩阵

实验	训练数据	目的
A	real only	baseline
B	real + 0.25x accepted synthetic	保守增强
C	real + 0.5x accepted synthetic	中等增强

实验	训练数据	目的
D	real + 1.0x accepted synthetic	压力测试

如果 A->B 提升，B->C 下降，说明 synthetic 有价值但比例过高。如果所有 synthetic 实验都下降，需要回到 QC 和生成策略。

10.4 指标

必须比较：

- Dice；
- NSD；
- lesion-wise F1；
- F1-AUC；
- ET/NETC/SNFH/RC 单类指标；
- $<27 \text{ mm}^3$ 小病灶 recall；
- $27\text{--}275 \text{ mm}^3$ 小病灶 recall；
- $>275 \text{ mm}^3$ 病灶分割指标；
- false positive components per case。

10.5 回溯分析

如果 synthetic 版本下降，按 manifest 回溯：

- 哪个 generator checkpoint 产生的样本最多；
- 哪类 label 最容易导致下降；
- 是否小病灶假阳性过多；
- 是否 RC 合成不合理；
- 是否 source case 分布偏向某机构；
- 是否 synthetic/real 比例过高；
- 是否某些 illegal label 或 corrected label 未处理干净。

11. G2 脚本设计

11.1 g2_build_manifest.py

职责：扫描真实训练集、验证集、合成数据目录，输出 manifest。

输入：

```
--train-root  
--validation-root  
--corrected-label-dir  
--output-dir
```

输出：

```
real_train_manifest_raw.csv  
real_train_manifest.csv  
real_validation_manifest.csv
```

关键逻辑：

- 递归识别训练病例，不能漏掉 UCSD - Training 。
- 对训练集要求 4 模态 + seg 。
- 对验证集只要求 4 模态。
- 读取 NIfTI header，记录 shape/spacing/dtype。
- 扫描 label unique values。
- 标记 corrected label overlay。
- 标记非法 label。

11.2 g2_apply_corrected_labels.py

职责：生成 corrected label 覆盖关系，或物理创建修正后的 working copy。

推荐默认：不覆盖原始数据，只在 manifest 记录 effective_seg_path 。

如果需要创建 working copy：

```
Training_corrected/  
BraTS-MET-xxxx/  
...
```

但这会占用大量存储，第一版不推荐。

11.3 g2_generate_batch.py

职责：批量调用 G1 推理接口。

功能：

- 读取 source case list。
- 排除 validation source。
- 控制 seed。
- 分片运行。
- 跳过已完成病例。
- 收集生成日志。
- 初步检查输出完整性。

失败日志格式：

```
{"case_id": "SYN-MET-000123", "source_case_id": "BraTS-MET-00010-000", "status": "faile
```

11.4 g2_qc_synthetic.py

职责：对 synthetic raw cases 做 L0/L1/L2 QC。

输入：

```
--synthetic-root  
--real-reference-manifest  
--output-dir
```

输出：

```
synthetic_candidate_manifest.csv  
synthetic_accepted_manifest.csv  
synthetic_rejected_manifest.csv  
qc_metrics.csv  
qc_summary.md  
figures/
```

每个 reject 必须有明确原因：


```
missing_modality
shape_mismatch
illegal_label
empty_mask
nan_image
roi_outside_brain
boundary_artifact
metadata_missing
teacher_inconsistent
```

11.5 g2_convert_to_nnunet.py

职责：把 real + accepted synthetic 转为 nnU-Net v2 raw dataset。

关键参数：

```
--dataset-id 261
--dataset-name BraTS2026_MET_RealSynth025
--synthetic-ratio 0.25
--copy-mode copy
--channel-order t1n,t1c,t2w,t2f
```

输出：

```
Dataset261_BraTS2026_MET_RealSynth025/
  imagesTr/
  labelsTr/
  dataset.json
  conversion_manifest.csv
```

11.6 g2_make_splits.py

职责：生成固定 fold。

规则：

- validation 只含真实病例；
- synthetic 不进入 validation；
- 若 synthetic 派生自 validation source，则剔除；
- 输出 nnU-Net 可读 splits_final.json 。

11.7 g2_teacher_qc.py

职责：调用 teacher 模型对 synthetic MRI 做预测，并计算一致性。

输入：

```
--synthetic-manifest  
--teacher-type s1_nnunet 或 brats_orchestrator  
--teacher-model-path  
--output-dir
```

输出：

```
teacher_predictions/  
teacher_qc_metrics.csv  
synthetic_teacher_filtered_manifest.csv
```

11.8 g2_feature_metrics.py

职责：计算 FID、MS-SSIM、医学特征距离。

建议第一版实现：

- ROI patch 级 MS-SSIM；
- lesion volume histogram；
- per-modality intensity distribution；
- 如果 S1 encoder 可用，再加 nnU-Net feature FID。

11.9 g2_report.py

职责：自动汇总 QC 与消融结果，生成报告。

输出：

```
reports/G2_synthetic_data_quality_report.md
```

报告内容：

- 数据来源；
- 生成器版本；

- 生成总数、接受数、拒绝数；
- 拒绝原因分布；
- 真实 vs 合成 label 分布；
- 图像质量统计；
- teacher consistency；
- 下游消融结果；
- 下一轮生成建议。

12. 里程碑与交付物

M0：准备阶段，1-2 天

目标：

- 确认训练集、验证集、corrected labels。
- 生成真实数据 manifest。
- 与 G1 锁定数据契约。
- 确认 S1/S2 baseline 路线。

交付物：

```
real_train_manifest.csv  
real_validation_manifest.csv  
corrected_label_overlay.csv  
G1_G2_contract.md
```

M1：smoke synthetic，2-3 天

目标：

- 让 G1 输出 10-20 个 synthetic cases。
- G2 跑通 QC。
- 转成 nnU-Net v2 dataset。
- 用 nnUNetv2_plan_and_preprocess --verify_dataset_integrity 检查。

交付物：

synthetic_raw/run_smoke/
synthetic_candidate_manifest.csv
synthetic_accepted_manifest.csv
Dataset260_BraTS2026_MET_SmokeSynth/
qc_summary_smoke.md

M2：第一版批量生成，3-5 天

目标：

- 生成 100-300 个候选合成病例。
- 通过 QC 筛选。
- 生成 montage 人工抽查。

交付物：

synthetic_accepted_manifest.csv
synthetic_rejected_manifest.csv
qc_metrics.csv
qc_figures/

M3：一折下游消融，3-7 天，取决于 GPU

目标：

- real only baseline。
- real + 0.25x synthetic。
- real + 0.5x synthetic。

交付物：

Dataset261_BraTS2026_MET_RealSynth025/
Dataset262_BraTS2026_MET_RealSynth050/
splits_final.json
ablation_results.csv

M4：迭代优化，1-2 周

目标：

- 根据 S1/S2 结果调整 G1 生成策略。
- 加入 teacher QC。
- 扩大 synthetic 数据量。
- 完成正式质量报告。

交付物：

```
G2_synthetic_data_quality_report.md
accepted synthetic dataset
next generation recommendations
```

13. 需要你补充的信息

G2 侧你需要确认：

1. 可用 GPU 型号、显存、数量。
2. 可用磁盘空间，尤其是能否额外保存 100-500GB synthetic data。
3. 是否允许使用 Docker。
4. 是否已有 S1/S2 nnU-Net baseline。
5. S1/S2 想用 nnU-Net 原始 label training 还是 region-based training。
6. 第一轮目标 synthetic 数量。
7. 是否已有固定 validation fold。
8. 是否需要把验证集 Validation/ 也转为 imagesTs 供提交或推理。
9. 队内是否允许使用 2025/2023 MET top algorithm 容器做 teacher。
10. BraTS-MET-01094-002 非法 label 6 的处理是否要向组织方确认。

14. 需要 G1 提供的信息

G1 必须提供：

1. checkpoint 路径和版本说明。
2. 推理脚本或命令。
3. Python/Conda/uv 环境依赖。
4. 输入数据格式。
5. 输出数据格式。
6. 支持的生成模式：2D、2.5D、3D、local insertion、full case。
7. 是否生成四模态，还是只生成一个模态。
8. 是否生成 label，还是只根据输入 label 生成图像。

- 9. 是否保持 source affine/header。
- 10. 是否支持 seed 复现。
- 11. 单病例推理时间和显存。
- 12. 失败时如何返回错误。
- 13. 是否支持分片： start/end 或 case list。
- 14. 是否支持批量生成时跳过已完成病例。

如果 G1 暂时只能提供切片式输出，G2 需要额外要求：

- 每个 slice 的 z-index。
- slice 拼回 3D 的 spacing。
- 是否存在跨切片 smoothing。
- 如何保证 lesion 不在 z 方向闪烁。
- 是否输出完整 3D seg.nii.gz 。

15. 风险与应对

风险	影响	应对
G1 输出不稳定	G2 脚本频繁返工	先锁数据契约，先做 10-20 个 smoke cases
synthetic label 与图像不一致	分割训练性能下降	teacher QC + 人工 montage
小病灶假阳性过多	detection F1 下降	小病灶分桶统计，不直接大规模混入
corrected labels 未应用	训练标签污染	manifest overlay，转换前强制检查
native space shape 差异大	脚本写死 shape 失败	全部基于 NIfTI header，交给 nnU-Net preprocessing
validation 泄漏	消融结果无效	source lineage 检查，validation 只含真实病例
FID/MS-SSIM 被误解	报告结论不可靠	明确其为辅助指标，最终看验证集消融
Docker/GPU 不可用	teacher model 难跑	先用 S1 nnU-Net baseline
存储爆炸	synthetic 数据难管理	先 0.25x/0.5x，保留 accepted，清理 rejected 中间图

16. 最小可行版本

第一版最小可行交付不需要做完所有指标。建议顺序：

1. g2_build_manifest.py
2. corrected label overlay
3. G1 smoke 输出 20 例
4. g2_qc_synthetic.py L0/L1
5. g2_convert_to_nnunet.py
6. nnUNetv2_plan_and_preprocess --verify_dataset_integrity
7. S1 跑一折 mini training
8. 写 smoke report

只要这条链路跑通，后续 FID、MS-SSIM、teacher QC、on-the-fly 都可以逐步加。

17. 附录 A：推荐配置文件

17.1 g2_paths.yaml

```
project_root: /Users/hwaigc/比赛+课题/ECNU-NYU2026
data_root: /Users/hwaigc/比赛+课题/ECNU-NYU2026/2026的task1以及数据
train_root: /Users/hwaigc/比赛+课题/ECNU-NYU2026/2026的task1以及数据/MICCAI-LH-BraTS2025-M
validation_root: /Users/hwaigc/比赛+课题/ECNU-NYU2026/2026的task1以及数据/Validation
corrected_label_dir: /Users/hwaigc/比赛+课题/ECNU-NYU2026/2026的task1以及数据/MICCAI-LH-Br
g2_output_root: /Users/hwaigc/比赛+课题/ECNU-NYU2026/G2_outputs
```

17.2 label_fix_rules.yaml

第一版建议只记录，不自动修：

```
allowed_labels: [0, 1, 2, 3, 4]
corrected_labels:
  BraTS-MET-01094-003: corrected-labels/BraTS-MET-01094-003-seg.nii.gz
  BraTS-MET-01184-002: corrected-labels/BraTS-MET-01184-002-seg.nii.gz
manual_review:
  BraTS-MET-01094-002:
    issue: contains illegal label value 6
    default_action: exclude_until_confirmed
```

17.3 g1_infer_template.yaml

```
command:
  - python
  - /path/to/g1_infer.py
args:
  checkpoint: /path/to/checkpoint.pt
  input_manifest: G2_outputs/manifests/real_train_manifest.csv
  output_dir: G2_outputs/synthetic_raw/run_20260518_g1_v1
  seed: 42
  device: cuda:0
  cases_per_source: 1
expected_outputs:
  modalities: [t1n, t1c, t2w, t2f]
  label: seg
  metadata: metadata.json
```

18. 附录 B：脚本伪代码

18.1 manifest 构建伪代码

```
for case_dir in recursive_find_case_dirs(train_root):
    case_id = case_dir.name
    paths = {
        "t1n": case_dir / f"{case_id}-t1n.nii.gz",
        "t1c": case_dir / f"{case_id}-t1c.nii.gz",
        "t2w": case_dir / f"{case_id}-t2w.nii.gz",
        "t2f": case_dir / f"{case_id}-t2f.nii.gz",
        "seg": case_dir / f"{case_id}-seg.nii.gz",
    }
    header_info = read_nifti_headers(paths)
    unique_labels = read_unique_labels(paths["seg"])
    effective_seg = corrected_overlay.get(case_id, paths["seg"])
    qc_pass, reasons = basic_real_case_qc(paths, header_info, unique_labels)
    write_manifest_row(...)
```


18.2 corrected labels overlay 伪代码

```
for corrected_seg in corrected_label_dir.glob("*-seg.nii.gz"):
    case_id = corrected_seg.name.replace("-seg.nii.gz", "")
    original_case_dir = find_case_dir(train_root, case_id)
    assert original_case_dir is not None
    original_seg = original_case_dir / corrected_seg.name
    assert same_shape_spacing(original_seg, corrected_seg)
    manifest[case_id]["effective_seg_path"] = corrected_seg
    manifest[case_id]["label_source"] = "corrected"
```

18.3 nnU-Net 转换伪代码

```
channel_order = ["t1n", "t1c", "t2w", "t2f"]
```

```
for nnunet_idx, row in enumerate(selected_real_and_synthetic_rows):
    nnunet_id = f"BratSMET_{nnunet_idx:06d}"
    for channel_idx, modality in enumerate(channel_order):
        src = row[f"{modality}_path"]
        dst = imagesTr / f"{nnunet_id}_{channel_idx:04d}.nii.gz"
        copy_or_link(src, dst)
    label_src = row["effective_seg_path"] if not row["is_synthetic"] else row["seg_path"]
    label_dst = labelsTr / f"{nnunet_id}.nii.gz"
    copy_or_link(label_src, label_dst)
```

18.4 synthetic QC 伪代码

```
for case in synthetic_cases:
    reasons = []
    if missing_files(case):
        reasons.append("missing_files")
    if not shape_spacing_consistent(case):
        reasons.append("shape_spacing_mismatch")
    if has_nan_inf(case):
        reasons.append("nan_or_inf")
    labels = unique_labels(case.seg)
    if not labels <= {0, 1, 2, 3, 4}:
        reasons.append("illegal_label")
    lesion_stats = connected_component_stats(case.seg, case.spacing)
    if lesion_stats.n_lesions == 0:
        reasons.append("empty_mask")
    intensity_stats = compute_intensity_stats(case)
    boundary_stats = compute_roi_boundary_stats(case)
    write_qc_row(case, reasons, lesion_stats, intensity_stats, boundary_stats)
```

19. 参考资料

本地资料：

- 2026的task1以及数据/BraTS2026_Task1_中文.md
- 2026的task1以及数据/BraTS2026_Task1_English.md
- 2026的task1以及数据/G2_数据生成与质量控制实现难度评估.md
- ECNU-NYU2026分工架构(2).docx
- 往年文章和code/2023/2023年第一名.pdf
- 往年文章和code/2025/2025年第一名.pdf
- 往年文章和code/2023/BraTS2023_Task1.md
- 往年文章和code/2023/BraTS2024_Task7.md
- 往年文章和code/2023/BraTS2024_Task8.md
- 往年文章和code/2025/brats/data/meta/metastases.yml

外部资料：

- BraTS 2026 Challenge Synapse 页面：
<https://www.synapse.org/Synapse%3Asyn74274097/docker/>

- Task 1 corrected-labels 官方讨论：
<https://www.synapse.org/Synapse%3Asyn74274097/discussion/threadId%3D12731>
- BrainLesion/BraTS Orchestrator: <https://github.com/BrainLesion/BraTS>
- BraTS Orchestrator 论文: <https://arxiv.org/abs/2506.13807>
- 2023 成人胶质瘤冠军方案 Just faking it: <https://arxiv.org/abs/2402.17317>
- 2025 成人胶质瘤 on-the-fly augmentation 方案: <https://arxiv.org/abs/2509.24973>
- BraTS 2025 Brain Metastases challenge manuscript: <https://arxiv.org/abs/2504.12527>
- BraTS inpainting challenge paper: <https://arxiv.org/abs/2305.08992>