S2 九路 fixed103 官方 MET 探索性横评

口径

九路使用相同的103个真实 T2W 开发病例、相同病例顺序、72列官方 MET 指标；CSV SHA、官方评估验证和 checkpoint 身份见验收清单。原 E 是比赛所选基座（epoch200）；B/E-SNFH/F 为各自从125连续扩展到175的选择结果；C40/D 是125轮训练预算中的选择点epoch50；K1/K2/K4为累计175轮。B/E-SNFH/F175的旧GPU包装验收作业曾失败，但其已完成的官方MET输出经独立CPU恢复批次验收通过；旧作业仍是失败，未被本表改写。训练预算、增强组合及历史来源不同，这不是九路等预算消融，也不替换原五路125轮等预算报告。

九路身份与训练基础

共同起点。比赛基座“原 E”是 Dataset264 缺失 T2W 补全数据上的 completion + focal 分割模型，训练至200轮后被选为比赛模型；其 checkpoint SHA 为 `4e5ff8d4a29fc498e4d91f9b0a71c34b818da6cd07d359ccabcc72dcb49e4267` 。这里的“原 E”不是后来的 E-SNFH，也不是 E_continue_final，更不是“无任何常规数据增强”的空白对照。后续 Screen125 与 K 路线均以原 E 的分割网络权重初始化各自独立训练；不是从 FixV3 full200 的最终权重出发，也不是九路互相接续训练。它们沿用固定的1035训练/103开发验证病例、seed `20260724` ，在线增强只在训练时启用；四模态生成器是冻结的，不随分割训练更新。原 E 本身则保留原来的200轮训练身份。原 E 选择记录与Screen125冻结计划可复核这条谱系。

共同增强底座 Route A。除原 E 外，八条后续路线都建立在 MET-AUG Route A 之上：在训练 patch 中按基准0.20概率尝试从训练集真实病灶供体移植组件，冻结的四个 Diffusion 模型在一致的标签 support 内生成四模态影像；候选通过多模态 QC 后才原子写入，support 外保持不变，失败则返回原 patch。Screen125 的 B/C40/D/E-SNFH/F是在这个底座上各改一项；K1/K2/K4使用后续重新构建的 RC27 或 small8 供体及多因素配置，不是把旧单项路线的checkpoint简单相加。FixV3/Route A策略和K1245原方案说明了各机制。

本表路线	训练谱系和预算	相对共同基础的实际变化
原 E	Dataset264 completion + focal 原始训练200轮； 本表直接使用比赛所选final checkpoint	不启用后来新增的在线 Route A；是其余八路共同的网络权重起点， 而非本次重新训练的第九个增强作业。
B175	原 E 权重 → Route A+B， 独立训练125轮后从本路线的完整网络/优化器/AMP/ 日志状态续至累计175；选175	B只增加按核心体积控制的各向同性缩放；不是早期名为“标准B” 的completion基线。
C40	原 E 权重 → Route A+C40，训练预算125轮； 按开发集规则选epoch50	仅把在线增强尝试概率从0.20提高到0.40；不是训练40轮，也不是再叠加B。
D50	原 E 权重 → Route A+D，训练预算125轮；选epoch50	首个病灶成功后，以0.20概率尝试第二个独立病灶；不含C40或B。
E-SNFH175	原 E 权重 → Route A+E-SNFH， 125轮后完整续至累计175；选175	在符合条件的纯ET候选上，以0.10概率尝试构造约1 mm的SNFH壳； 它不是比赛原 E，也不是训练了175轮的原 E。
F175	原 E 权重 → Route A+F，125轮后完整续至累计175； 选175	按训练集原生病灶负荷改变增强尝试概率：旧F为低负荷较高、高负荷较低， 总体平均仍约0.20；与K1的F*方向/资格门不同。
K1	原 E 权重 → 独立K1训练至累计175，选175； 原作业超时后从本路线epoch100完整checkpoint续训， 不更换初始化或重置175轮学习率终点	E-SNFH* + F* + X1 + B①+B②：重新校准SNFH壳；F*按train-only负荷分层**递增**概率；X1引入RC27供体、目标RC占比0.023； B①限制RC供体scale=1， B②按同表型经验体积分布受限缩放。 `F_STRICT_PREREG_GATE=false` ， K1依独立fallback**工程资格门**运行，不等于F科学门通过。
K2	原 E 权重 → 独立K2训练175轮，选175	E-SNFH* + D* + X1 + X2 + B①+B②：同样使用RC27和受限B设计； *D按train-only患者内体积分布/距离设计第二灶（概率0.20）， X2把生成使用量自epoch83线性衰减至epoch125的0，之后保持0至175； **不启用F**。*
K4	原 E 权重 → 独立K4训练175轮，选175	E-SNFH* + X3：使用**不含RC来源**的small8池，把可用核心下限降至8 voxel并保持单连通；不启用X1/RC27、B、D或F*，负荷权重恒为1。批次名“RC-aware”不能据此误读成K4实际生成RC。

“从原 E 权重初始化”只指新实验的网络参数起点，不等于继承原 E 的优化器进度；Screen125计划明确 `resume=false` 。相反，B/E-SNFH/F的125→175扩展以及K1超时后的恢复，才是从**本路线**完整checkpoint恢复网络、优化器、AMP和日志并延续累计175轮学习率曲线。原E、FixV3 full200、E-SNFH125/175不能因为名称相似而视作同一个连续作业。

Screen125五路按固定103的内部 `ema_fg_dice` 从25/50/75/100/125候选中选点；B/E-SNFH/F的Extend175继续比较125/150/175，三路均选175。K路线按用户后续修订改为175轮，从25至175每25轮留点并按同一规则选175。选点轮次与训练预算是两个不同字段：C40/D虽选50，却来自各自125轮预算实验；原五路125轮等预算横评仍应单独查看。Extend175验收、K路线175修订和K1/K2/K4验收记录了实际选择结果。K路线一次改变多个因素，表中任何差异都不能单独归因于RC、壳、F*或X3。

指标字典与方向

本报告的“官方 MET”是 `config=mets` 、 `vol_threshold=27` 、 `overlap_threshold=0.2` 的病例级输出。四个区域分别是 ET（增强肿瘤，标签3）、RC（切除腔，标签4）、TC（肿瘤核心，标签1U3）、WT（全肿瘤，标签1U2U3）。**TC和WT均不包含RC标签4**；不能把RC数值加到TC/WT。官方配置先以病灶DSC作二分图匹配（匹配门槛 `0.000001` ），解析器对大/小病灶检出另要求匹配DSC≥ `0.2` ，这两个阈值不是一回事。下表中“大”指参考病灶的 `volume≥27` ，“小”指 `volume<27` ；阈值作用在**参考病灶**而不是预测病灶的体积。定义依据为本地MET配置与官方CSV解析器。

每个区域有以下18列，四个区域共72列；CSV后缀 `_et/_rc/_tc/_wt` 只改变所评价的区域。箭头表示**单项读数的期望方向**，不是单项通过科学门或综合排名。

CSV列族（每区域）	指标含义与计算口径
`all_instance_tp/fp/fn_*`	Panoptica的病例级病灶实例真阳性/假阳性/漏检数；不是像素数。
`all_instance_f1_*`	全部病灶的病例级检出F1（输出字段 `rq` ，即 `2TP/(2TP+FP+FN)` ）；不是逐体素Dice。
`large_instance_tp/fp/fn_*`	参考大病灶按匹配DSC≥0.2计TP，否则计FN； 解析器的 `large_instance_fp` 直接使用该区域的**全部**未匹配预测FP，并非只筛出“大预测”的FP。
`large_instance_f1_*`	用上一行的TP/FN和全部FP计算病例级 `2TP/(2TP+FP+FN)` ； 分母为0时解析器写0，故可在全部103例上有数。
`small_instance_tp/fp/fn_*`	参考小病灶按匹配DSC≥0.2计TP， 否则计FN； `small_instance_fp` 同样复制该区域的**全部**未匹配预测FP，不是“小预测FP”。
`small_instance_f1_*`	上述小病灶TP/FN与全部FP形成的病例级F1；无参考小病灶时为空。
`lesionwise_dsc_mean_*`	表中简称“病灶Dice”：对参考**大病灶**的重叠Dice取病例内均值， 漏检大病灶及全部未匹配FP按0惩罚。不是全图global Dice， 也不是所有小病灶的平均。
`lesionwise_nsd_mean_*`	同一大病灶及FP惩罚集合的归一化表面Dice/边界贴合度均值； 漏检和FP按0惩罚。
`lesionwise_hd95_mean_*`	同一集合的95百分位边界距离均值； 漏检大病灶及FP按373的最大惩罚替代无穷大。
`lesionwise_dsc_std_*` 、 `lesionwise_nsd_std_*` 、 `lesionwise_hd95_std_*`	同一病例内上述病灶/惩罚值集合的标准差； 不是103病例之间的标准差。

`mean/std/median` 是官方CSV末尾的**跨病例汇总行**：本报告的原值取 `mean` 行，按该列有限病例求平均（病例权重相同），不是先汇总全队列TP/FP/FN再算micro-F1；末尾 `std` 行也不同于上表 `lesionwise_*_std_*` 的病例内标准差。某列为空或非有限值时保留缺失，**不补0**；有定义但实际失败的惩罚0/373则是解析器已明确写入的真实评分。各指标分别报告有效病例数 `n` ，因此不同列的均值不应直接相减为同病例效应。

九路比较方法

1. **看原值：**先在下表对照同一列的九路官方 `mean` ，用上表箭头判断方向，同时查看该列有效 `n` ；这里不自创跨区域/跨指标加权总分。RC病灶Dice只有15例有效，不能和WT的87例当作同等精度证据。

2. **看同病例差：**完整配对表覆盖36对×72列；对每个指标只取双方在同一个病例都为有限值的交集，列出双方原始均值、双方共同病例均值、 `paired_n` 和排除数。高好列收益= `A-B` ；低好列（FP、FN、HD95）收益= `B-A` ，所以**正收益一律表示表中A路线更有利**。TP和标准差的方向字段仅供机械筛选，仍需结合F1、Dice及FP/FN解释。
3. **看不确定性：对每对每列的病例级收益做20,000次有放回bootstrap（seed= `20260831` ），取2.5%/97.5%分位数为95%CI；W/T/L是A逐病例收益 `>0/=0/<0` 的计数， `n=W+T+L` 。未校正双侧 p 按bootstrap均值落在0两侧的尾概率计算，并非正式隐藏测试或多重比较校正后的证明；重采样单位是病例条目而非患者组**。CI跨0表示此数据不足以给出稳定的正负方向，不能把"原值第一"自动写成正式胜出。

下表全部是**官方CSV的原始mean**，不是配对共同有效病例均值。Dice/F1越高越好，FP/FN越低越好。ET/RC/TC/WT病灶Dice的有效例数依次为85/15/86/87；WT大小病灶F1与FP/FN的有效例数依次为46/103/103。WT全部病灶F1的n依路线变化，逐项见648行原值。

路线（选择点）	ET Dice↑	RC Dice↑	TC Dice↑	WT Dice↑	WT全部F1↑	WT小F1↑	WT大F1↑	WT FP/例↓	WT FN/例↓
原 E (200)	0.6117	0.3112	0.6577	0.6176	0.7283	0.2947	0.6885	0.6602	3.1553
B (175)	0.6177	0.3533	0.6608	0.5874	0.7078	0.2977	0.6567	0.9126	3.1456
C40 (50/125)	0.6342	0.3443	0.6594	0.5442	0.6314	0.0905	0.6088	1.1942	3.8835
D (50/125)	0.5843	0.4538	0.6227	0.5284	0.6413	0.2907	0.6152	1.4660	2.9223
E-SNFH (175)	**0.6482**	0.3322	0.6875	0.6235	0.7242	0.2564	0.6886	0.6990	3.2233
F (175)	0.6304	0.3266	0.6737	0.6032	0.7195	0.2733	0.6705	0.8252	3.1650
K1 (175)	0.6373	0.3230	**0.6881**	**0.6303**	**0.7484**	0.2620	**0.7015**	**0.6311**	3.1262
K2 (175)	0.6109	0.3325	0.6511	0.6007	0.7029	0.2171	0.6735	0.7573	3.2233
K4 (175)	0.6271	0.3272	0.6705	0.6130	0.7326	0.2829	0.6873	0.7573	**3.0680**

RC Dice原值最高的是D的0.4538，但只在15例中定义，且D的WT Dice为九路最低、WT FP最高。WT小病灶F1原值最高的是B175的0.2977，原E为0.2947；差距很小，不能仅凭均值宣布稳健获胜。K1的WT Dice、全部/大病灶F1和WT FP在本表更有利，但未显示小病灶F1优势。各标签全部72项原值在CSV中，不自造综合评分。

同病例对原 E

下表为**路线相对原 E**的WT病灶Dice配对收益（高好）；双方原始均值仍列出。每行paired n=87，W/T/L为该路线胜/平/负；CI和p来自同病例20,000次bootstrap，**p未作多重比较校正**。原始均值差与paired差在本指标恰好一致，因为两方法有效病例集合相同；其他指标不能作这个假设。

路线	路线原值	原E原值	配对收益 [95%CI]	W/T/L	p
B175	0.5874	0.6176	-0.0303 [-0.0594, -0.0046]	38/2/47	0.0193
C40	0.5442	0.6176	-0.0734 [-0.1216, -0.0255]	27/2/58	0.0031
D50	0.5284	0.6176	-0.0892 [-0.1315, -0.0501]	37/1/49	<0.0001
E-SNFH175	0.6235	0.6176	+0.0059 [-0.0253, +0.0367]	54/2/31	0.7049
F175	0.6032	0.6176	-0.0144 [-0.0505, +0.0206]	44/2/41	0.4218
K1	0.6303	0.6176	+0.0126 [-0.0147, +0.0396]	49/1/37	0.3525
K2	0.6007	0.6176	-0.0169 [-0.0424, +0.0055]	45/2/40	0.1468
K4	0.6130	0.6176	-0.0046 [-0.0368, +0.0241]	52/1/34	0.7831

K1相对原E在WT Dice的CI跨0；K1对E-SNFH175的WT Dice配对收益+0.0067、95%CI [-0.0181,+0.0319]、p=0.5919，也跨0。K1对原E的RC Dice原值0.3230对0.3112，n=15、收益+0.0118、95%CI [-0.0370,+0.0813]，同样没有稳健证据。E-SNFH175对原E的ET/TC Dice分别+0.0366 [0.0120,0.0650]、+0.0298 [0.0082,0.0543]，但WT和RC CI跨0。上述所有CI/p只作未校正探索性筛选。

FP/FN保护与结论边界

原E的WT FP/FN为0.6602/3.1553个/例；K1为0.6311/3.1262，配对低好收益分别+0.0291（95%CI [-0.1650,+0.2136]）和+0.0291（[-0.0874,+0.1553]），均不能证明保护通过。B175的WT FP升至0.9126，较原E多0.2524/例，方向化收益-0.2524，95%CI [-0.4466,-0.0680]。D50的WT FN较少，但FP显著更

多，不能只报召回一面。

完整36对×72指标逐项列有双方原始均值、双方共同病例均值、配对n、方向化收益、95%CI、W/T/L和未校正p；八路对原E便于直接过滤。所有结果用同一个用于选checkpoint的fixed103开发集报告，且多路线/多指标比较未校正，**只能标记为exploratory**，不可声称正式优越性或据此自动启动K5。K5原科学门仍未通过。